

ResNet(서민솔, 박준영, 정준호)

Deep Residual Learning for Image Recognition

Deeper neural networks are more difficult to train. We present a residual learning framework to ease the training of networks that are substantially deeper than those used previously. We...

 <https://arxiv.org/abs/1512.03385>



▼ Abstract

- 깊은 네트워크에서 학습을 용이하게 하기 위해 **residual learning 프레임워크**를 제안
 - 입력에 대한 참조를 가지는 residual function을 학습하도록
- residual network가 최적화하기 더 쉽고, 증가된 깊이 때문에 정확도를 향상시킬 수 있음
- depth of representation은 많은 visual recognition task에서 중요하다.

▼ Introduction

deep layer의 필요성

- Deep CNN은 image classification에서 획기적인 성과를 보여줌. 깊이가 중요
- 저수준, 중간수준, 고수준의 특징들을 자연스럽게 통합 → 특징의 level이 풍부해진다.

문제 제시

- 단순히 깊이 층을 쌓는게 더 나은 네트워크를 만드는 것은 아니다.
 - vanishing gradient / exploding gradient → normalized initialization 그리고 intermediate normalization으로 해결하여 SGD와 backpropagation을 통해 수렴을 시작
- 네트워크의 깊이가 증가함에 따라 정확도가 포화되는 것을 넘어 성능이 급격하게 저하됨.
 - 과적합 때문이 아님. 그냥 훈련 오류가 증가




Figure 1. Training error (left) and test error (right) on CIFAR-10 with 20-layer and 56-layer “plain” networks. The deeper network has higher training error, and thus test error. Similar phenomena on ImageNet is presented in Fig. 4.

- 만약 얇 + 깊 일 때 깊을 Identity를 설정하고 얇을 얇만 훈련했던 가중치를 그대로 가져오면 더 깊은 모델이 얇은 모델보다 큰 훈련오류를 가질 이유가 없음을 의미한다.
- 그러나 현대의 최적화 기법들이 Identity mapping과 동등하거나 더 나은 해를 찾지 못한다.

해결

- deep residual learning framework : underlying mapping ($H(x)$)를 직접 학습하는 대신 residual mapping ($F(x) = H(x) - x$)를 학습하도록 명시적으로 설정
- 이렇게 residual mapping을 학습하는 것이 unreferenced mapping($H(x)$)를 학습하는 것보다 훨씬 쉽다.
- 이러한 $F(x) + x$ 의 formulation은 shortcut connection을 갖는 feedforward neural network로 구현될 수 있다. 즉 하나 이상의 층을 건너 뛰는 거임




Figure 2. Residual learning: a building block.

- 이러한 shortcut connecton은 추가 파라미터나 computational complexity를 증가시키지 않는다.

실험

- ImageNet에 대해
 1. 극도의 deep residual net은 최적화하기 쉽지만 일반 plain net은 깊이가 증가할 수록 높은 training error
 2. deep residual ent은 깊이를 늘리면 정확도 향상
- CIFAR-10 에 대해서도 실험 할 거임 ㅋㅋ

결과

- 개굿!
- downstream task에서도 일반화 굿!


▼ Related Work

▼ Residual Representations

- VLAD : residual vector를 인코딩하는 표현방식
- Fisher vector : VLAD의 확률적 버전
- vector quantization 에서도 원본 벡터를 인코딩 하는 것보다 잔차 벡터 ($r = x - c$) 를 인코딩 하는 것이 효과적
- Multigrid의 대안으로 hierarchical basis preconditioning이 있는데 이는 두 스케일 사이의 잔차 벡터를 나타내는 변수에 의존
 - 문제의 적절한 reformulation 과 preconditioning이 최적화를 단순화할 수 있음

▼ Shortcut Connections

- MLP를 학습시키는 초기 기법 중 하나는 네트워크의 입력을 출력에 직접 연결하는 linear layer를 추가하는 것
- 또한 gradient vanishing / exploding gradient를 해결하기 위해 중간 레이어들을 auxiliary classifier에 직접 연결
- 또한 GoogleNet은 Inception layer가 하나의 지름길 분기와 여러 개의 깊은 분기들로 구성



- Highway networks는 gating function을 갖는 shortcut connection을 제안했는데 데이터에 의존하며 파라미터를 가짐
- 이때 shortcut connection이 닫히는 경우(0에 가까워짐) 그냥 Highway net은 residual mapping이 아닌 그냥 unreference mapping을 학습한다.

▼ Deep Residual Learning

▼ Residual Learning

- $H(x)$: 몇 개의 layer에 의해 학습되어야 할 underlying mapping
 x 는 첫 번째 layer의 input
- 몇 개의 nonlinear layer가 복잡한 함수를 근사할 수 있다면 residual mapping ($H(x) - x$) 또한 근사할 수 있다.
- 우리는 $H(x)$ 를 직접 근사하는 대신 **residual function ($H(x) - x$)을 근사하도록 명시적으로 설정한다.**
- 추가된 층들이 identity mapping으로 구성될 수 있으면 더 깊은 모델은 더 얇은 모델보다 training error가 커서는 안된다.
- 그러나 성능 저하가 있다는 말은 최소한의 identity mapping을 근사하는 데 어려움을 겪고 있음을 시사한다. → residual learning으로 재정식화
- 이러한 재정식화는 preconditioning하는 데 도움을 준다.




Figure 7. Standard deviations (std) of layer responses on CIFAR-10. The responses are the outputs of each 3×3 layer, after BN and before nonlinearity. **Top:** the layers are shown in their original order. **Bottom:** the responses are ranked in descending order.

- Residual net의 출력은 보통 작음 $\rightarrow$ Identity mapping(x)를 기준으로 작은 변화 ($F(x)$) $\rightarrow$ Identity mapping을 기준으로 작은 perturbation을 찾는 것

▼ Identity Mapping by Shortcuts




Figure 2. Residual learning: a building block.

$$y = F(x, \{W_i\}) + x$$

$$F = W_2 \sigma(W_1 x)$$

- $F + x$ 는 element wise addition
- 이러한 shortcut connection은 파라미터와 계산 복잡도를 추가하지 않음
- F 와 x 의 차원은 같아야 한다. 만약 같지 않다면 선형 투영을 하여 차원을 맞춘다.

$$y = F(x, W_i) + W_s x$$




Figure 5. A deeper residual function $\mathcal{F}$ for ImageNet. Left: a building block (on 56×56 feature maps) as in Fig. 3 for ResNet-34. Right: a “bottleneck” building block for ResNet-50/101/152.

- feature map의 크기가 절반이 되면 channel x2
- downsampling은 stride 2를 갖는 합성곱 층을 이용
- 마지막 layer에 avg pooling과 softmax 사용하는 1000-d FC layer

Residual Network

- plain 네트워크 기반으로 residual connection 삽입
 - 입력과 차원이 동일한 경우에는 Identity shortcut 그대로 사용
 - 차원이 증가하는 경우에는
 1. 여전히 Identity mapping을 수행하되, 증가된 차원은 0으로 패딩
 2. $y = F(x, W_i) + W_s x$ 를 사용하여 차원을 맞춘다. (1x1 conv)
 - downsampling하면 size는 절반 / channel은 2배
 - size는 stride 2로, channel은 1x1 conv로 조절

▼ Implementation

- 증강을 위해 짧은 변 길이 [256, 480] 범위에서 무작위 리사이즈 → 224 x 224 크기의 패치를 무작위 추출하고 픽셀 단위 평균을 제거
- 색상 증강
- conv → BN → activation
- batch_size = 256, optimizer = SGD, lr = 0.1, scheduling = 1/10, iteration = 600000, weight_decay = 0.0001, momentum = 0.9
- test시에서는 10 crop 테스트
- 여러 스케일에서 점수를 평균

▼ Experiments

▼ ImageNet Classification

Plain Networks

layer name	output size	18-layer	34-layer	50-layer	101-layer	152-layer
conv1	112×112	7×7, 64, stride 2				
		3×3 max pool, stride 2				
conv2_x	56×56	$\begin{bmatrix} 3 \times 3, 64 \\ 3 \times 3, 64 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 64 \\ 3 \times 3, 64 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$
conv3_x	28×28	$\begin{bmatrix} 3 \times 3, 128 \\ 3 \times 3, 128 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 128 \\ 3 \times 3, 128 \end{bmatrix} \times 4$	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 4$	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 4$	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 8$
conv4_x	14×14	$\begin{bmatrix} 3 \times 3, 256 \\ 3 \times 3, 256 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 256 \\ 3 \times 3, 256 \end{bmatrix} \times 6$	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 6$	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 23$	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 36$
conv5_x	7×7	$\begin{bmatrix} 3 \times 3, 512 \\ 3 \times 3, 512 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 512 \\ 3 \times 3, 512 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$
	1×1	average pool, 1000-d fc, softmax				
FLOPs		1.8×10^9	3.6×10^9	3.8×10^9	7.6×10^9	11.3×10^9

- 18층과 34층 plain network 평가

	plain	ResNet
18 layers	27.94	27.88
34 layers	28.54	25.03

Table 2. Top-1 error (% , 10-crop testing) on ImageNet validation. Here the ResNets have no extra parameter compared to their plain counterparts. Fig. 4 shows the training procedures.

- plain network는 깊이가 깊어지니까 error가 커짐.




Figure 4. Training on **ImageNet**. Thin curves denote training error, and bold curves denote validation error of the center crops. Left: plain networks of 18 and 34 layers. Right: ResNets of 18 and 34 layers. In this plot, the residual networks have no extra parameter compared to their plain counterparts.

- 왼쪽 그림을 보면 plain network는 degradation problem이 전체적으로 관찰된다.
- 하지만 이것은 gradient vanishing 때문이 아니다.
- plain이 실제로 경쟁력 있는 정확도를 달성을 하므로 solver로서의 역할을 하지만 지속적으로 낮은 수렴 속도를 갖는다고 생각할 수 있다.

Residual Networks




Figure 4. Training on **ImageNet**. Thin curves denote training error, and bold curves denote validation error of the center crops. Left: plain networks of 18 and 34 layers. Right: ResNets of 18 and 34 layers. In this plot, the residual networks have no extra parameter compared to their plain counterparts.

	plain	ResNet
18 layers	27.94	27.88
34 layers	28.54	25.03

Table 2. Top-1 error (% , 10-crop testing) on ImageNet validation. Here the ResNets have no extra parameter compared to their plain counterparts. Fig. 4 shows the training procedures.

- 주요 관찰
 1. residual learning을 통해 더 낮은 training error를 보이고 validation data에도 잘 일반화된다.
 2. plain network와 비교했을 때 오류율 감소 : 깊은 layer는 residual learning이 효과적

3. 18층에서는 plain network와 유사한 정확도를 보이지만 더 빠르게 수렴한다. : residual learning이 더 빠른 수렴을 용이하게 한다

Identity vs Projection Shortcuts

model	top-1 err.	top-5 err.
VGG-16 [41]	28.07	9.33
GoogLeNet [44]	-	9.15
PReLU-net [13]	24.27	7.38
plain-34	28.54	10.02
ResNet-34 A	25.03	7.76
ResNet-34 B	24.52	7.46
ResNet-34 C	24.19	7.40
ResNet-50	22.85	6.71
ResNet-101	21.75	6.05
ResNet-152	21.43	5.71

Table 3. Error rates (% , **10-crop** testing) on ImageNet validation. VGG-16 is based on our test. ResNet-50/101/152 are of option B that only uses projections for increasing dimensions.

A : 차원 증가시 0 padding : 파라미터가 없는 경우

B : 차원 증가 시 projection shortcut을 사용하고 나머지는 Identity shortcut을 사용

C : 모든 지름길을 projection shortcut으로 구성

- 세 가지 옵션 모두 plain network보다 우수함을 보인다.
- B가 A보다 성능이 좋은 이유는 padding된 차원에서는 residual learning이 이루어지지 않았기 때문
- C가 B보다 근소하게 성능이 좋은 이유는 projection shortcut으로 인한 추가된 파라미터 덕분
- A/B/C간의 차이가 적은 것은 projection shortcut이 성능 저하 문제를 해결하는 데 필수적이지 않다는 것을 시사

Deep Bottleneck Architectures




Figure 5. A deeper residual function $\mathcal{F}$ for ImageNet. Left: a building block (on 56×56 feature maps) as in Fig. 3 for ResNet-34. Right: a “bottleneck” building block for ResNet-50/101/152.

- 더 깊은 네트워크를 위해서 bottleneck 구조로 수정
 - $1 \times 1 \rightarrow 3 \times 3 \rightarrow 1 \times 1$: 1×1 으로 채널 수를 줄였다가 3×3 연산을 하고 1×1 으로 채널 수를 늘림
- 이러한 bottleneck에서 Identity shortcut이 중요한 이유는 고차원 끝 단계에 대해 projection shortcut을 연결하면 파라미터수가 증가하여 비효율적이기 때문

50-layer ResNet

- 3 layer bottleneck block을 사용하고 B 옵션을 사용

101 - layer and 152 - layer ResNet

model	top-1 err.	top-5 err.
VGG-16 [41]	28.07	9.33
GoogLeNet [44]	-	9.15
PReLU-net [13]	24.27	7.38
plain-34	28.54	10.02
ResNet-34 A	25.03	7.76
ResNet-34 B	24.52	7.46
ResNet-34 C	24.19	7.40
ResNet-50	22.85	6.71
ResNet-101	21.75	6.05
ResNet-152	21.43	5.71

Table 3. Error rates (% , **10-crop** testing) on ImageNet validation. VGG-16 is based on our test. ResNet-50/101/152 are of option B that only uses projections for increasing dimensions.

method	top-1 err.	top-5 err.
VGG [41] (ILSVRC'14)	-	8.43 [†]
GoogLeNet [44] (ILSVRC'14)	-	7.89
VGG [41] (v5)	24.4	7.1
PReLU-net [13]	21.59	5.71
BN-inception [16]	21.99	5.81
ResNet-34 B	21.84	5.71
ResNet-34 C	21.53	5.60
ResNet-50	20.74	5.25
ResNet-101	19.87	4.60
ResNet-152	19.38	4.49

Table 4. Error rates (%) of **single-model** results on the ImageNet validation set (except [†] reported on the test set).

- 152층 ResNet은 VGG - 16/19보다 더 낮은 복잡도를 가진다.
- 그리고 깊이가 쌓이면 쌓일수록 성능이 좋아짐.

Comparisons with State-of-the-art Methods

method	top-5 err. (test)
VGG [41] (ILSVRC'14)	7.32
GoogLeNet [44] (ILSVRC'14)	6.66
VGG [41] (v5)	6.8
PReLU-net [13]	4.94
BN-inception [16]	4.82
ResNet (ILSVRC'15)	3.57

Table 5. Error rates (%) of **ensembles**. The top-5 error is on the test set of ImageNet and reported by the test server.

- 서로 다른 깊이를 가진 6개의 모델을 결합하여 앙상블 했을 때 개국

▼ CIFAR-10 and Analysis

CIFAR-10에서도 Residual learning이 짱~

Analysis of Layer Responses





Figure 7. Standard deviations (std) of layer responses on CIFAR-10. The responses are the outputs of each 3×3 layer, after BN and before nonlinearity. **Top:** the layers are shown in their original order. **Bottom:** the responses are ranked in descending order.

- layer response의 std
- layer response는 3×3 의 출력으로 BN 이후 activation function 적용 이전
- ResNet이 plain대응 모델보다 더 작은 response를 가진다. 그러니까 residual function이 unreference 함수보다 0에 가깝다는 것을 지지한다.
- 깊은 ResNet일수록 response의 크기가 더 작다 → 입력을 거의 유지한채 작은 수정만 가하는 식으로 학습이 된다.

Exploring Over 1000 layers



- 1202층에 대해서도 해봄
- 근데 110층보다 낮음
- 이건 과적합 때문임
- 1202층 네트워크는 CIFAR-10에 비해 너무 큼