Review+ResNet

He et al. (2015) Deep Residual Learning for Image Recognition

---

본 논문은 목표 함수를 잔차 매핑으로 재정의하는 Residual Network를 제안함. Residual Network는 레이어가 아주 깊을 때도 모델을 잘 수렴시키고 좋은 성능을 보임. 아주 깊은 레이어를 잘 처리해야 이미지 관련 태스크에 필요한 위계적 구조 모델링을 할 수 있기 때문에 중요한 기여를 했다고 볼 수 있음.

This paper suggests **Residual Network** that preconditions desired function with residual mapping(content). This contributes to better convergence and performance for very deep networks(contribution). This finding is meaningful since processing deep layers is crucial to image-related tasks(why).

#Deep_Convolutional_Network #Residual_mapping #identity_mapping #shortcut_connections

---

Overview

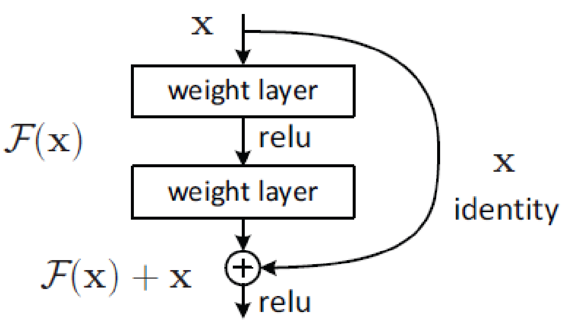

Figure 2. Residual learning: a building block.

- 적절한 재기술이나 사전조건화는 모델 최적화를 쉽게 만든다.
  "Good reformulation or preconditioning can simplify the optimization(p. 2)."
- Residual Network는 깊은 레이어들이 잔차 매핑을 적합하고 목표 함수를 H(x)에서 F(x) + x로 재기술한다

  Residual Network explicity lets stacked layers fit a residual mapping and reformulate target function H(x) to F(x) + x.

In Detail

1. This paper suggests **Residual Network** that preconditions desired function with residual mapping.

   본 논문은 목표 함수를 잔차 매핑으로 재정의하는 Residual Network를 제안함

: Neural Networks find it hard to learn the latent goal function H(x) as the layers gets deep.

본 인공신경망은 레이어가 깊어질수록 latent 공간의 목표함수 H(x)를 잘 배우지 못함.

: The degradation in accuracy does not lie in overfitting problem, but in optimization problem. Increased error in during training even when identity mappings and learned layers were added attests this.

이때 발생하는 정확도 저하 degradation 문제는 과적합 문제가 아니라 최적화 문제임. Identity 매핑과 이미 학습시킨 레이어를 모델에 추가시켰을 때도 학습 에러가 증가한다는 사실은 모델이 잘 최적화되지 않아서 degradation이 발생한다는 것을 보여줌.

: Residual Network introduces residual function F(x) that is easier to learn for the network.

Residual Network는 F(x)라는 잔차 함수를 도입함. 네트워크가 더 쉽게 배울 수 있는 함수임.

: Residual function F(x) refers to the difference between desired output and the input, which is exactly the reason why it is called 'residual'.

잔차 함수 F(x)는 입력값과 원래 목표 함수 간 차이를 말함. '잔차'라고 불리는 이유임.

: H(x) is reformulated as "F(x) + x" and the input simply adds up to the outputs of residual building block

원래 H(x)는 F(x)+x로 재기술되고 입력값은 잔차 블록의 출력에 단순 합해짐.

: The golden function that the network should predict is still H(x), but with residual mapping, the network only has to predict the residual between x and H(x).

네트워크가 예측해야 할 최종 정답은 여전히 H(x)지만, 잔차 매핑이 있기 때문에 네트워크는 입력값과 H(x)의 차이만 예측하면 됨.

: (relevant equations)

$$F(x) := H(x) - x \qquad eqn(1)$$

$$H(x) = F(x) + x \qquad eqn(2)$$

$$y = F(x, \{W_i\}) + x \qquad eqn(3)$$

2. To reduce complexity, **zero-padding, deep bottleneck design** and **global average pooling** is introduced.

   모델 복잡도를 줄이기 위해 zero-padding, 바틀넥 디자인, GAP이 이용되었음.

: Residual mapping does not require additional parameters. It is operated by simple element-wise addition.

잔차 매핑은 추가 파라미터가 필요하지 않음. 요소별 합으로 연산됨.

: As layer gets deeper, time and spatial complexity may skyrocket. ResNet prevents this by zero-padding, deep bottleneck design, and global average pooling.

하지만 레이어가 깊어질수록 시간과 공간 복잡도가 급격하게 올라갈 수 있음. ResNet은 이걸 zero-padding과 바틀넥 디자인, GAP로 방지함.

: Zero-padding is mainly used for ResNet 18/34. To control the number of channel dimensions, ResNet adds features maps that consists of number zeros.

zero-padding은 ResNet1 18/34에 주로 이용돼서 채널 차원 수를 조절함. ResNet은 0으로만 이루어진 feature map을 channel 축을 따라 붙여줌.

: Deep bottleneck design is utilized in ResNet 50/101/102. It consists of 1x1, 3x3 and again 1x1 convolution. 1x1 convolutions controls the channel dimension so that heavy 3x3 convolution can be done with small FLOPs and parameters.

바틀넥 디자인은 ResNet 50/101/102에 이용됨. 1x1, 3x3, 1x1 컨볼루션으로 이루어지는데, 1x1 컨볼루션이 채널 차원을 조절해줘서 3x3 컨볼루션이 적은 수의 채널에 대해 이뤄질 수 있게 함.

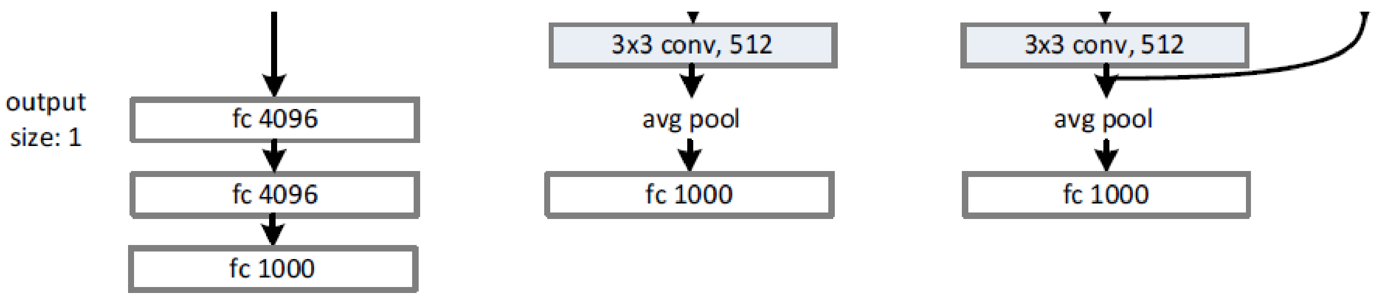

: Global Average Pooling is employed at the end of the model. GAP replaces heavy FCs(4096, 4096) as in VGG model, resulting in even lower complexity with deeper layers.

GAP는 모델 끝에서 쓰임. GAP은 VGG에서 두 개의 4096차원 FC 레이어를 대체해서, 더 깊은 레이어를 가지고도 더 낮은 복잡도를 가질 수 있게 함.

3. This contributes to better convergence and performance for very deep networks(contribution)

   ResNet은 아주 깊은 네트워크에서도 잘 수렴하고 더 좋은 성능을 보인다는 contribution을 함.

: Residual networks attested better(lower) traing, validation, and test errors compared to that of plain networks or other deep-thin networks. It also converges fasters than plain networks.

ResNet은 더 낮은 학습, validation, 테스트 에러를 보였고 일반 네트워크보다 수렴도 빨랐음.

: What is also striking about the result is that the deeper the network is, the less error it shows. This means that ResNet makes more contribution aside from better optimization for deeper networks.

더 놀라운 점은 네트워크가 깊어질수록 에러가 더 적어졌다는 것임. ResNet이 최적화가 아닌 다른 이점도 가지고 있다는 의미임.

: This indicates ResNet makes better H(x) while showing a faster and optimized convergence.

ResNet이 수렴도 잘 시키지만 더 좋은 목표 함수를 만든다는 것을 의미함.

: (results)

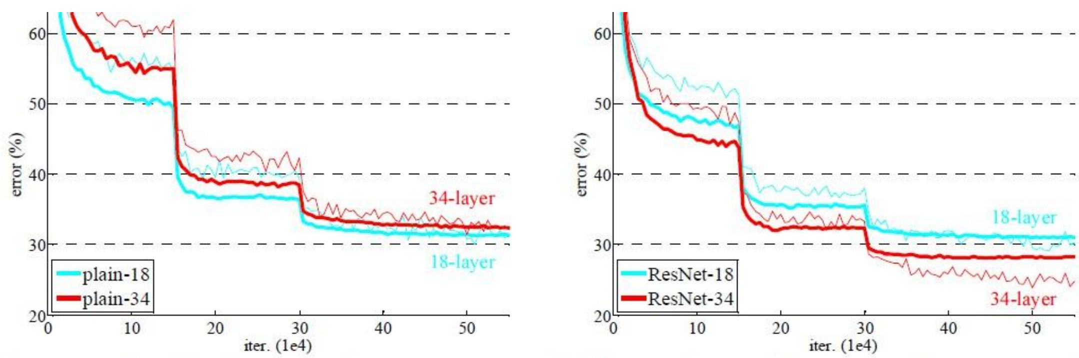

Figure 4. Training on **ImageNet**. Thin curves denote training error, and bold curves denote validation error of the center crops. Left: plain networks of 18 and 34 layers. Right: ResNets of 18 and 34 layers. In this plot, the residual networks have no extra parameter compared to their plain counterparts.

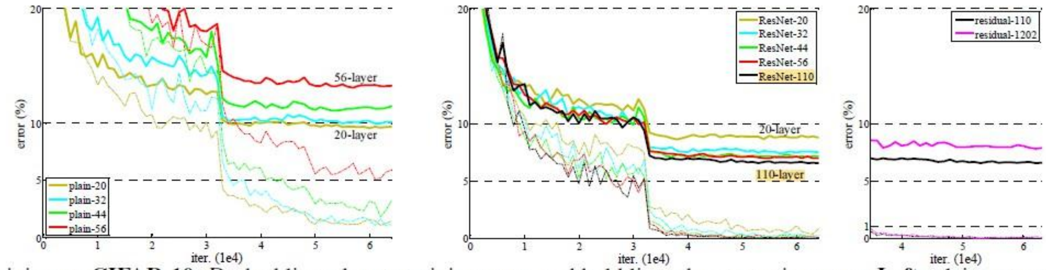

Figure 6. Training on **CIFAR-10**. Dashed lines denote training error, and bold lines denote testing error. **Left**: plain networks. The error of plain-110 is higher than 60% and not displayed. **Middle**: ResNets. **Right**: ResNets with 110 and 1202 layers.

4. This finding is meaning since processing deep layers is crucial to image-related tasks(why)

: Image-related task requires learning of hierarchical features of input image and Deep Convolutional Networks does that.
