

Attention Is All You Need

Title

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. (2017). Attention is all you need. *Advances in neural information processing systems*, 30.

Abstract

- 기존의 지배적인 시퀀스 변환(sequence transduction) 모델은 인코더와 디코더를 포함하는 복잡한 RNN 또는 CNN 기반 구조에 의존해왔음
- 또한 최고 성능 모델들은 encoder-decoder 사이에 attention mechanism을 결합하여 성능을 높였음
- 본 논문에서는 RNN과 CNN을 완전히 제거하고, **attention mechanism만을 기반으로 하는 새로운 네트워크 구조 Transformer**를 제안함
- 두 가지 번역 실험(WMT14 En-De, En-Fr)에서 Transformer는 기존 SOTA 모델보다 ****더 높은 성능 (BLEU)****을 달성하면서도
학습이 훨씬 병렬화 가능하고 훈련 시간이 짧음을 보임
- 추가적으로 번역뿐 아니라 **English constituency parsing**에서도 높은 성능을 보여 Transformer가 다른 태스크로도 일반화될 수 있음을 시사함

Introduction

✓ 논문에서 다루고 있는 주요 연구 문제나 질문

- 기존 sequence-to-sequence 모델에서 RNN은 시퀀스 길이가 길어질수록 **순차적 계산(sequential computation)** 때문에 학습이 느리고 병렬화가 어려움
- CNN 기반 모델은 병렬화는 가능하지만, 멀리 떨어진 토큰 간 의존성을 연결하기 위해 여러 층이 필요해 long-range dependency 학습이 어려움

✓ 논문의 기여 (Contribution)

- Attention mechanism은 입력과 출력 길이에 구애받지 않고 강력한 dependency modeling을 가능하게 함
- 그러나 대부분의 모델은 attention을 RNN 구조와 함께 사용해왔음
- 본 논문은 이러한 흐름에서 벗어나, **오직 self-attention과 attention 기반 연산만으로 구성된 sequence transduction 모델 Transformer**를 제안함
- Transformer는 병렬화가 극대화되어 학습 속도를 크게 개선하면서도 번역 성능에서 SOTA를 달성함

Background

Recurrent seq2seq models

- RNN/LSTM/GRU 기반 seq2seq는 언어 모델링과 번역에서 SOTA였으나
순차적 계산으로 인해 병렬화가 제한되는 구조적 한계를 가짐

📌 CNN 기반 seq2seq models (ByteNet, ConvS2S 등)

- CNN 기반 모델은 병렬 처리가 가능하지만,
토큰 간 거리가 멀어질수록 dependency를 연결하기 위해 더 많은 연산 단계가 필요함
- ConvS2S는 dependency 연결 비용이 거리 n 에 대해 선형
- ByteNet은 dependency 연결 비용이 로그 수준

📌 Self-attention

- 시퀀스의 표현을 만들기 위해 하나의 시퀀스 안에서 서로 다른 위치의 토큰을 연결시키는 attention mechanism
- reading comprehension, summarization, entailment 등 다양한 태스크에서 활용됨

📌 End-to-end memory networks

- sequence-aligned recurrence 대신 반복적 attention mechanism을 사용하는 구조
- 이전 attention 결과를 다음 attention의 입력으로 사용하는 recurrence 형태
- 간단한 QA, language modeling에서 좋은 성능을 보임

➡ Transformer는 기존 연구들과 달리, **sequence-aligned recurrence(RNN)나 convolution 없이 self-attention만으로 encoder/decoder 표현을 계산한** 최초의 transduction 모델임

🔍 Model Architecture

✅ Transformer 구조 개요

- Transformer는 encoder-decoder 구조를 유지하지만
기존의 recurrent layer나 convolution layer를 전부 제거하고
(1) self-attention + (2) position-wise FFN만을 반복적으로 쌓아 구성함

✅ Encoder

- $N = 6$ 개의 동일한 layer stack으로 구성됨
- 각 layer는 2개의 sub-layer로 구성됨
 1. Multi-Head Self-Attention
 2. Position-wise Feed-Forward Network (FFN)
- 각 sub-layer에는 residual connection + layer norm이 적용됨

$\text{LayerNorm}(x + \text{Sublayer}(x))$

- 모든 sub-layer 출력 차원은 ($d_{\text{model}} = 512$)로 고정됨

✅ Decoder

- $N = 6$ 개의 동일한 layer stack으로 구성됨

- 각 layer는 3개의 sub-layer로 구성됨
 1. Masked Multi-Head Self-Attention
 2. Encoder-Decoder Multi-Head Attention
 3. Position-wise FFN
- decoder의 self-attention은 미래 token 정보를 참조하지 않도록 masking을 적용함
- masking은 softmax 입력에서 illegal connection을 $(-\infty)$ 로 처리하여 확률이 0이 되게 하는 방식

✓ Attention Mechanism

Transformer에서 attention은 총 3가지 방식으로 사용됨

1. Encoder self-attention
2. Decoder masked self-attention
3. Encoder-decoder attention (decoder query가 encoder output에 attention)

✓ Scaled Dot-Product Attention

- (Q)(query) : 현재 위치에서 "무엇을 찾고 싶은가"
- (K)(key) : 모든 위치에 대한 "특성 설명"
- (V)(value) : 실제로 전달할 정보

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) V$$

- (QK^T) 는 query와 key의 유사도를 의미
- dot product는 차원이 커질수록 값이 커지고 softmax가 gradient가 거의 0인 영역으로 들어갈 수 있음
- 이를 방지하기 위해 $(\sqrt{d_k})$ 로 scaling하여 안정적인 학습을 유도함

✓ Multi-Head Attention

- 하나의 attention을 수행하는 대신,
서로 다른 projection을 가진 여러 attention head를 병렬 수행한 뒤 concat하여 최종 출력 생성
- multi-head attention의 핵심 효과:
 - 서로 다른 representation subspace에서 동시에 정보를 보게 함
 - single-head에서는 attention weighted average가 정보 손실을 유발할 수 있음
- 논문 기본 설정:
 - head 수 ($h=8$)
 - 각 head의 ($d_k = d_v = 64$)
 - 전체 계산량은 single-head full dimension과 유사하게 유지됨

✓ Position-wise Feed-Forward Network (FFN)

$$\text{FFN}(x) = \max(0, xW_1 + b_1)W_2 + b_2$$

- 각 token position마다 독립적으로 동일한 FFN이 적용됨
- kernel size 1인 convolution을 2번 적용한 것과 유사하다고 설명함

✓ Embedding & Softmax (중요 구현 디테일)

- input embedding과 output embedding, 그리고 pre-softmax linear layer가 **같은 weight**를 공유함
- embedding 값은 $(\sqrt{d_{\text{model}}})$ 로 scaling하여 사용함

✓ Positional Encoding

- recurrence나 convolution이 없으므로 순서 정보를 주입해야 함
- positional encoding을 embedding에 더하는 방식으로 해결함

$$PE(pos, 2i) = \sin(pos/10000^{2i/d_{\text{model}}})$$

$$PE(pos, 2i + 1) = \cos(pos/10000^{2i/d_{\text{model}}})$$

- sin/cos를 선택한 이유:
 - 상대적 위치(pos+k)가 pos의 선형 결합으로 표현될 수 있어 상대 위치 attention 학습이 쉬울 것으로 가정
 - learned positional embedding과 성능은 유사했지만, sin/cos는 학습 길이보다 더 긴 시퀀스에도 extrapolation 가능할 수 있어 채택함

🔍 Training

- ✓ 데이터셋
- ✓ Models
- ✓ Evaluation Metrics
- ✓ Implementation Details
- ✓ 주요 실험 결과
- ✓ 결과 분석 및 해석

✓ 데이터셋

- WMT 2014 English-German
 - 약 4.5M sentence pairs
 - BPE(byte-pair encoding)
 - shared source-target vocab $\approx 37,000$ tokens
- WMT 2014 English-French
 - 36M sentence pairs
 - 32,000 word-piece vocab

✓ Models / Training Setup

- Hardware
 - 8 NVIDIA P100 GPUs 사용
 - Training time
 - base model: 100K steps, 약 12시간
 - big model: 300K steps, 약 3.5일
-

✓ Optimizer

- Adam optimizer 사용
 - ($\beta_1 = 0.9$)
 - ($\beta_2 = 0.98$)
 - ($\epsilon = 10^{-9}$)

(Transformer에서 매우 중요한 학습 세팅)
 - Learning rate schedule
 - warmup_steps = 4000
 - 이후 inverse square root decay 적용
-

✓ Regularization

- Residual Dropout
 - sub-layer output에 dropout 적용 후 residual connection 수행
 - Label smoothing
 - ($\epsilon_{ls} = 0.1$)
 - perplexity는 악화될 수 있으나 BLEU는 개선됨
-

✓ Evaluation Metrics

- BLEU (bilingual evaluation understudy)
-

✓ Results

- WMT14 En-De:
 - Transformer(big) BLEU = 28.4
 - 기존 SOTA(ensemble 포함)보다 2.0 이상 향상
 - WMT14 En-Fr:
 - Transformer(big) BLEU = 41.8
 - single-model SOTA 달성
-

✓ Inference Details

- beam search
 - beam size = 4
 - length penalty $\alpha = 0.6$
 - max output length = input length + 50

✓ Model Variations (A~E)

- (A) head 개수 변화
 - 너무 적거나 너무 많으면 성능 하락
- (B) (d_k) 감소
 - 성능 저하 → compatibility 계산이 단순하지 않음을 시사
- (C) layer 수 / model size 증가
 - bigger models are better
- (D) dropout 변화
 - overfitting 방지에 효과적
- (E) positional encoding 변경
 - learned embedding vs sin/cos 성능 거의 동일

✓ Additional Experiment: English Constituency Parsing

- Transformer가 translation 외의 태스크에서도 일반화되는지 검증하기 위해 parsing 실험 수행
- WSJ Penn Treebank 기반 실험에서 strong baseline 수준의 F1 달성
- semi-supervised setting에서는 기존 parsing 모델들과 비교해도 매우 강력한 성능을 보임

📖 Conclusion

✓ Transformer

- attention에만 기반한 첫 sequence transduction 모델
- recurrent layer와 convolution layer를 multi-head self-attention으로 대체
- translation 태스크에서 기존 RNN/CNN 기반 모델보다 훨씬 빠르게 학습하면서도 더 높은 BLEU 성능을 달성함

✓ Limitation

- self-attention은 시퀀스 길이 (n)에 대해 계산 복잡도가 ($O(n^2)$)이므로 매우 긴 입력에서는 계산량이 커질 수 있음
- 이를 해결하기 위해 restricted/local attention을 future work로 제시함

✓ 향후 연구 방향

- 텍스트뿐 아니라 이미지, 음성, 영상 등 다른 modality에도 적용
- long sequence를 위한 restricted attention 연구
- generation을 덜 sequential하게 만드는 연구 방향 제시
