




2026-1 BASIC STUDY ML 2주차

Supervised Learning

SESSION LEADER: 20기 박준희

2026.01.15



Orientation

자기소개 간단하게 진행해주세요 :D

이름, 나이, 학과, ML 세션에 들어온 계기, ML 관련 경험 정도만 간단히!

과제 우수자 발표

윤지원 님

화면 공유해주시고
5분 이내로 설명 부탁드립니다 :)



What is Statistical Learning?

Keywords

Statistical Learning

Predict f
Prediction, Inference
Modeling

Modeling

Parametric, Non-parametric
Loss Function, Fit
Evaluation

What is Statistical Learning?

Statistical learning refers to a vast set of tools for understanding data

→ “데이터를 이해하는 것”

What is Statistical Learning?

Input variables($X_1, X_2 \dots$) – e.g. advertising budget

- predictors, independent variables, features
- 예측 변수, 독립 변수, 피쳐

Output variable(Y) – e.g. sales

- response, dependent variables
- 반응 변수, 종속 변수
- ...


Q. some relationship between Y and $X = (X_1, X_2, \dots, X_p)$

Y와 X간에는 어떤 관계가 있는가

What is Statistical Learning?

$$Y = f(X) + \epsilon$$

*f is some fixed but unknown function of $X_1, \dots, X_p$,
and ϵ is a random error term independent of X with mean zero*



f represents the systematic information that X provides about Y
→ f는 X가 Y에 대해 가진 체계적인(기계적, 구조적인) 정보를 나타냄

What is Statistical Learning?

그런데 일반적으로 우리는 f 를 모르는 상태!

one must **estimate f based on the observed points**

우리가 가진 관측치(데이터)를 통해 f 를 추정해야 한다

결국 statistical learning이란,
이러한 **f 를 추정하는 일련의 과정 및 방법론**

“predicting f through data”

Why Estimate f ?

Prediction

set of inputs X are readily available,
but the output Y cannot be easily obtained
정확한 Y 값을 예측하는 데 초점(모델의 해석가능성보다 성능이 중요)

We can predict Y using

$$\hat{Y} = \hat{f}(X)$$

$\hat{f}$ represents our estimate for f , and $\hat{Y}$ represents the resulting prediction for Y

예시:

- Gradient Boosting Machines
- k-Nearest Neighbors

Why Estimate f ?

$$\begin{aligned} E(Y - \hat{Y})^2 &= E[f(X) + \epsilon - \hat{f}(X)]^2 \\ &= \underbrace{[f(X) - \hat{f}(X)]^2}_{\text{Reducible}} + \underbrace{\text{Var}(\epsilon)}_{\text{Irreducible}}, \end{aligned}$$

average(expected value) of the **squared difference**
between the predicted and actual value of Y

estimate f with the aim of **minimizing reducible error!**

Why Estimate f ?

Inference

understanding the association between Y and the set of X
X와 Y간의 관계를 이해하거나 해석하는 데 초점.
 $\hat{f}$ 의 형태와 해석 가능성에 중점

예시:

- 광고비와 매출; 고객의 구매여부 간의 관계 분석(선형회귀, 로지스틱 회귀)
- 변수 선택 및 변수 중요도 분석(Lasso/Ridge 회귀)
- 특정 변수가 판매량에 미치는 영향 분석(Decision Trees)

※목적에 따른 구분일 뿐, 별개는 아님


How do we estimate f ?

Model

In general, a model is an **idealized representation** of a system

With data, we'll treat a model as “**some mathematical rule or function to describe relationships between variables**”,

→ “변수 간의 관계를 설명하는 수학적 규칙 혹은 함수”



How do we estimate f ?

Model

Dataset

x	y
x_1	y_1
x_2	y_2
$\vdots$	$\vdots$
x_n	y_n

Observation

(x_i, y_i)

- Independent variable
- **Input**
- **Feature**
- **Attribute**

- Dependent variable
- **Output**
- **Outcome**
- **Response**

Prediction

If we use x to predict y , the predictions are denoted as

$$\hat{y} = \{\hat{y}_1, \hat{y}_2, \dots, \hat{y}_n\}$$

Models

Some models we will see in the next few lectures:

$$\hat{y}_i = \theta_0 + \theta_1 x_i$$

$$\hat{y}_i = \theta_0$$

$$\hat{y}_i = x_i^\top \theta$$

Parametric models

How do we estimate f ?

Model

- **Parametric vs Non-parametric**
- **Deterministic vs Probabilistic**
 - Deterministic: 동일한 입력에 대해 항상 동일한 출력을 제공
 - 예: 선형 회귀, 딥러닝(Softmax 확률을 제외한 내부 연산들)
 - Probabilistic: 출력이 확률 분포 형태로 제공
 - 예: Bayesian Linear Regression, Gaussian Process, Hidden Markov Model

How do we estimate f ?

Parametric Methods

(two-step model-based approach)

1. make an **assumption** about the functional form, or shape, of f
 2. use the training data to **fit or train** the model
- reduces the problem of estimating f down to estimating a set of parameters !
 - potential disadvantage: the model we choose might not match the true unknown form of f
 - 예시: 선형 회귀, 로지스틱 회귀, 선형 커널 SVM, LDA ...

How do we estimate f?

Parametric Methods

- The data informs us about the parameters 데이터를 통해 파라미터를 추정
- x , y values are not parameters because we directly observe them
- Sample-based estimate of parameter θ is written with a hat($\hat{\theta}$)

θ	Model parameter(s)	}	$\hat{y} = \theta_0 + \theta_1 x$	Any linear model with parameters $\theta = [\theta_0, \theta_1]$
$\hat{\theta}$	Estimated parameter(s), "best" fit to data in some sense			
		}	$\hat{y} = \hat{\theta}_0 + \hat{\theta}_1 x$	The "best" fitting linear model with parameters $\hat{\theta} = [\hat{\theta}_0, \hat{\theta}_1]$

How do we estimate f ?

Non- Parametric Methods

- do not make explicit assumptions about the functional form of f
- seek an estimate of f that is as close as possible to the observed data
- disadvantage: requires a very large number of observations and has the risk of overfitting
- 예시: k -NN, KDE, Random Forest, 비선형 커널 SVM, 딥러닝...

How do we estimate f ?

Trade-off between Prediction Accuracy and Model Interpretability




FIGURE 2.7. A representation of the tradeoff between flexibility and interpretability, using different statistical learning methods. In general, as the flexibility of a method increases, its interpretability decreases.

Modeling Process

1. Choose a model

Which **model** should we choose? How should we represent the world?
데이터를 어떤 관점에서 해석? 어떤 모델로 표현?
(해결하려는 문제에 따라 모델 선택)

2. Choose a loss function

How do we **quantify prediction error**?
모델의 예측과 실제 값 간의 차이를 측정하는 방법을 정의

3. Fit the model

How do we choose the **best parameters** of our model given the data?
주어진 데이터로 모델의 최적 파라미터를 어떻게 선택할 것인가?

4. Evaluate model performance

How do we **evaluate** whether this process ended with a good model?
모델의 성능을 평가하여 목표를 잘 달성했는지 확인



What is Supervised Learning?

Keywords

**Supervised vs
Unsupervised**

Objectives


Regression vs Classification

Setup

Model, Parametric, Non-parametric


지도학습 ?
“정답이 있는 문제를 학습”
Model = Learner

Supervised vs Unsupervised



- 스팸 메일 구분하기
- 내일 강수량(mm) 예측하기

→ “정답(label)”이 있는 문제



- 네안데르탈인의 유골 분류하기
- scRNA-seq 세포 구분하기

→ “정답(label)”이 없는 문제
(최대한 분류할 수는 있지만, 끝내 정답을 알 수 없다)

Supervised vs Unsupervised

Supervised Learning


Data: $x \in \mathcal{X}$ (usually a vector)

Label: $y \in \mathcal{Y}$

Dataset: $(x^{(1)}, y^{(1)}) , (x^{(2)}, y^{(2)}) , \dots , (x^{(n)}, y^{(n)})$

Supervised vs Unsupervised

• Image Classification



• Price Prediction



Supervised vs Unsupervised

- Next word Prediction

“The cat sat on the ____ .

- Text Classification

 이동진 평론가   6년 전

기생충

영화 · 2019

★ 4.5

상승과 하강으로 명징하게 직조해낸 신랄하면서 처연한 계급 우화.

Supervised Learning

- Classification**

discrete (finite)

airplane



automobile




bird



cat



deer




dog




frog



horse



ship




truck



- Regression**

continuous (real)

$$y \in \mathcal{Y}$$



Supervised Learning

- **Setup : True Function을 잘 근사할 수 있도록**

- **True function:** f , where $f(x^{(i)}) = y^{(i)}$
- **Want to find:** $g(x) \approx f(x)$
- **Function class:** $\mathcal{G}$
- **Goal:**

$$g_{\theta}(x) \approx f(x)$$

$$g_{\theta} \in \mathcal{G}$$

Find g_{θ} from function class that approximates the true function **well**.

Supervised Learning

- **Approximation given a dataset**
 - **Similar function values for all input x [Infeasible]**

$$g_{\theta}(x) \approx f(x)$$

- **Similar function values for given dataset:**

$$g_{\theta}(x^{(i)}) \approx f(x^{(i)}) = y^{(i)}$$

**모든 입력에 대해 모델이 true function f 를 재현하는 것은 현실적으로 불가능,
학습은 주어진 데이터셋을 기반으로 모델을 f 와 가깝게 만드는 작업!**

Supervised Learning

- **Approximate well?**

- **Similar function value can be measured:**

$$g_{\theta}(x^{(i)}) \approx f(x^{(i)}) = y^{(i)}$$

- **Pointwise Loss:**

Can be mean-squared error, cross-entropy, etc.

$$\ell(g_{\theta}(x^{(i)}), y^{(i)})$$

- **Loss:**

$$\mathcal{L}(\theta) = \sum_{i=1}^n \ell(g_{\theta}(x^{(i)}), y^{(i)})$$

Loss Function (손실함수):

예측값과 실제값(레이블)의 차이를 구하는 기준
모델의 학습 과정에서 “좋다/나쁘다”의 판단 기준

문제 특성(회귀, 분류..)에 따라
적절한 손실함수를 선택해야!

모델이 실제 함수를 얼마나 잘 근사하는지 측정하는 과정!
개별 데이터 샘플의 손실을 합산한 총 손실 값을 줄이는 게 학습의 목표

Supervised Learning

- **Given dataset (with label):**

$$\{(x^{(1)}, y^{(1)}), (x^{(2)}, y^{(2)}), \dots, (x^{(n)}, y^{(n)})\}$$

- **Set function class: $\mathcal{G}$**

- **Set loss function: ℓ**

- **Find $g_{\theta} \in \mathcal{G}$ that minimizes:**

$$\mathcal{L}(\theta) = \sum_{i=1}^n \ell(g_{\theta}(x^{(i)}), y^{(i)})$$

**지도학습은 데이터셋, 함수 클래스 G , 손실함수 f 를 설정하고, 최적의 모델 g_{θ} 를 학습하는 과정.
특히, 데이터셋에서 잘 작동할 뿐 아니라 새로운 데이터에서도 잘 일반화되는 모델을 만들어야.**



Model Training

Keywords

**Dimensions of a
Supervised Learner**

Model, Loss Function, Optimization

Loss Function

MSE, MAE, MLE

Dimensions of a Supervised Learner

“모델을 훈련”한다 = 훈련 데이터셋에 가장 잘 맞는 “모델 파라미터”를 찾는다.

Model: $g(x|\theta), \quad g \in \mathcal{G}$

Loss Function: $E(\theta|\mathcal{X}) = \sum_t L(y^t, g(x^t|\theta))$

Optimization Procedure: $\theta^* = \arg \min_{\theta} E(\theta|\mathcal{X})$

모델 선정

- 입력 x 와 파라미터 θ 를 기반으로 예측값 생성

정답을 통한 모델 성능 측정

- 데이터셋 X 에 대해 계산된 총 손실

정답을 가장 잘 맞추는 모델 파라미터 탐색


- 파라미터 θ 를 조정하여 총 손실 E 최소화
- 어떤 estimator를 써야 할까?

Loss Function

What is a Loss Function?

예측값과 실제값(레이블)의 차이를 구하는 기준

Quantifies the error between output of the algorithm and given target value



Loss Function

Loss Function penalizes bad predictions

Regression

- Mean Squared Error (MSE)

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

- Mean Absolute Error (MAE)
- Mean Bias Error (MBE)

Classification

- Binary Cross Entropy (이진분류)

$$BCE = -\frac{1}{N} \sum_{i=0}^N y_i \cdot \log(\hat{y}_i) + (1 - y_i) \cdot \log(1 - \hat{y}_i)$$

- Categorical Cross Entropy (다중분류)


$$CCE = -\frac{1}{N} \sum_{i=0}^N \sum_{j=0}^J y_j \cdot \log(\hat{y}_j) + (1 - y_j) \cdot \log(1 - \hat{y}_j)$$

- Hinge Loss
- SVM Loss

Loss Function – MSE, MAE

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

$$MAE = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i|$$



- **Idea는 분산과 동일**
 - 분산 : “편차 제곱의 평균”
 - MSE : “잔차(residual) 제곱의 평균”
- MSE vs MAE
 - 거리를 제곱으로 할지, 절댓값으로 할지의 차이
 - MSE – 제곱, MAE – 절댓값
- **MSE** : 거리가 크면 Penalty가 더 세다
→ 이상치에 민감하다
- **MAE** : 거리가 커도 Penalty가 덜하다
→ 이상치에 덜 민감하다

Loss Function – Entropy

$$H(X) = -\sum p(x) \log p(x)$$
$$= \sum p(x) \log \frac{1}{p(x)}$$

Entropy


- “Expectation of Surprise” : 놀라움의 정도를 수치화

흰공 9개, 검은공 1개가 있다. 어떤 경우가 더 놀라운가?

- 흰공을 뽑았을 때? vs 검은공을 뽑았을 때?

- **확률이 높아지면 놀라움(surprise)은 작아진다.**
→ **놀라움은 확률과 반비례**

확률이 매우 낮을 때, 엔트로피가 지나치게 커지는 것을 방지하기 위해 로그(log) 사용



Loss Function – Cross Entropy

Entropy에서 착안하여..

- Cross Entropy: 예측분포($q(x)$)와 실제분포($p(x)$)의 차이를 측정
- $q(x)$ 가 실제로 발생한 사건(높은 $p(x)$)에 낮은 확률을 할당하면, 큰 Loss 발생
- 모델 $q(x)$ 를 개선하여 $p(x)$ 를 더 잘 근사하도록 학습

이진 분류의 경우

$$\begin{aligned} H(p, q) &= - \sum p(x) \log q(x) \\ &= \sum y \log \frac{1}{\hat{y}} + (1 - y) \log \frac{1}{1 - \hat{y}} \end{aligned}$$

Loss Function – MLE

Likelihood Function

P(X|θ) : 주어진 파라미터 θ에서 데이터 X가 발생할 확률

- 주어진 모델과 파라미터 θ에 의해 데이터가 얼마나 잘 설명되는지를 평가하는 척도
- ‘주어진 데이터가 어떤 확률 분포에 맞는 정도’를 수치화한 것

$$\underbrace{P(\theta|X)}_{\text{A posterior probability}} = \frac{\overbrace{P(X|\theta)}^{\text{Likelihood}} \overbrace{p(\theta)}^{\text{A prior probability}}}{\underbrace{P(X)}_{\text{Marginal probability}}} \propto P(X|\theta)P(\theta)$$

Definition (Likelihood)

For $X_1, \dots, X_n \stackrel{iid}{\sim} f_X(x; \theta)$, where θ denotes a parameter of interest. The **likelihood function** is

$$L(\theta; \mathbf{X}) = L(\theta; X_1, \dots, X_n) = \prod_{i=1}^n f_X(X_i; \theta)$$

관측 데이터 X가 주어졌을 때, 특정 파라미터 θ가 참일 확률

Loss Function – MLE

Log Likelihood Function

- Likelihood는 관찰 데이터의 모든 확률값을 곱하는 형태로 정의
- 0~1 사이 값으로 이루어진 확률값들의 곱
n이 클 수록, 매우 작아지는 (0에 가까워지는) 문제

$$\theta_{MLE} = \arg \max_{\theta} P(X|\theta)$$

$$= \arg \max_{\theta} \prod_i P(x_i|\theta)$$

로그 (log) !!



$$\theta_{MLE} = \arg \max_{\theta} \log P(X|\theta)$$

$$= \arg \max_{\theta} \log \prod_i P(x_i|\theta)$$

$$= \arg \max_{\theta} \sum_i \log P(x_i|\theta)$$

Loss Function – MLE

Maximum Likelihood Function

- 특정 데이터 분포를 가정하여 관찰 데이터를 설명하는 최적의 파라미터를 찾는 방법
- 이 과정에서 MLE는 손실함수를 최소화하는 방향으로 학습

Definition (Maximum likelihood estimator, MLE)


For $X_1, \dots, X_n \stackrel{iid}{\sim} f_X(x; \theta)$, the MLE of θ is

$$\hat{\theta}_{MLE} = \underset{\theta}{\operatorname{argmax}} L(\theta; \mathbf{x}).$$

which is equivalent to maximize the logarithm of $L(\theta; \mathbf{x})$ which we call the log-likelihood

$$\ell(\theta; \mathbf{x}) = \log L(\theta; \mathbf{x}).$$

- Likelihood $P(X|\theta)$ 를 최대화(Maximize)하는 파라미터 θ 를 찾는 것이 목표!
- 이게 결국 loss function을 최소화하는 것과 동일



Log likelihood Functions

Bernoulli Distribution

$$\log L(p) = \sum_{i=1}^n (y_i \log \hat{p} + (1 - y_i) \log(1 - \hat{p}))$$

Binomial Distribution

$$\log L(p) = \log \binom{n}{c} + \sum_{i=1}^n (y_i \log \hat{p} + (1 - y_i) \log(1 - \hat{p}))$$

Multinomial Distribution

$$\log L(p) = \sum_{i=1}^n \sum_{j=1}^c y_{ij} \log \hat{p}_j$$

Normal Distribution

$$\log L(\mu) \approx -\frac{\sum_{i=1}^n (y_i - \mu)^2}{\sigma^2}$$

**우리가 만든 모델과 정답의 차이를 보여주는 것이 Loss Function
정답에 가까운 distribution을 찾아주는 것이 MLE**

04

Model Selection / Evaluation

Keywords

Evaluation

Performance Metrics

Error

Bias–Variance Trade–off

**Underfitting &
Overfitting**

**Cross Validation &
Regularization**

우리의 목표 :


**Train Error / Test Error를
최대한 낮추고 싶다!**

우리의 목표 :

~~Train Error~~ / Test Error를 최대
한 낮추고 싶다!


Error?

- **Error** : deviation from an actual value by a prediction or expectation of that value
- **Loss Function** :
 - 모델 학습 과정에서 최소화되어야 하는 함수로서, 모델의 오류(Error)를 정량화하는 역할



$$\begin{aligned}
 MSE &= E[y - \hat{f}(x)]^2 \\
 &= E[f(x) + \epsilon - \hat{f}(x)]^2 \\
 &= E[f(x) - \hat{f}(x)]^2 + E[\epsilon]^2 + 2E[\epsilon(f(x) - \hat{f}(x))] \\
 &= [Var(\hat{f}(x)) + Bias(\hat{f}(x))^2] + Var(\epsilon) \\
 &= Reducible Error + Irreducible Error
 \end{aligned}$$

Bias/Variance Trade-Off



복잡한 모델


- High Variance
 - 데이터가 달라질 때, 예측값의 변동폭이 큼
- Low Bias
 - 정답을 대부분 맞힘

단순한 모델


- Low Variance
 - 데이터가 달라져도 예측값의 변동폭이 작음
- High Bias
 - 정답을 대부분 벗어남

- Bias error is an error from erroneous assumptions in the learning algorithm.
 - High bias can cause an algorithm to miss the relevant relations between features and target outputs (underfitting).
- Variance is an error from sensitivity to small fluctuations in the training set.
 - High variance may result from an algorithm modeling the random noise in the training data (overfitting).


Underfitting vs Overfitting



overfitting









underfitting



good balance

Underfitting vs Overfitting

	Underfitting	Just right	Overfitting
Symptoms	• High training error • Training error close to test error • High bias	• Training error slightly lower than test error	• Very low training error • Training error much lower than test error • High variance
Regression illustration			
Classification illustration			
Deep learning illustration			
Possible remedies	• Complexify model • Add more features • Train longer		• Perform regularization • Get more data

Underfitting vs Overfitting

Underfitting

- 모델이 훈련 데이터의 패턴을 제대로 학습하지 못한 상태
- Train, Test set 모두에서 성능이 좋지 않음
- 모델 복잡도 키우기
- 유용한 특징을 선별하기 위한 feature engineering
- 데이터에서 노이즈 또는 불필요한 특징 제거.
- 학습 시간을 늘리기 (예: 딥러닝에서 학습 epoch 수 증가).

Overfitting

- 모델이 훈련 데이터의 패턴뿐만 아니라 노이즈까지 학습한 상태.
- Train set에는 성능이 좋지만, 새로운 데이터에 대한 일반화 (generalization) 성능이 낮음
- 훈련 데이터를 늘려 모델이 더 일반적인 패턴을 학습하도록 유도
- 모델 복잡도 줄이기
- 정규화(Regularization) 기법 사용
- Early Stopping을 사용하여 Validation Loss가 줄지 않으면 학습 중단
- 드롭아웃(Dropout)을 적용하여 신경망의 일부 뉴런을 무작위로 무시

Model Selection

Inductive Bias : Occam's Razor

If performances are similar, use the simpler one because...

- Simpler to use (lower computational complexity)
- Easier to train (lower space complexity)
- Easier to explain (more interpretable)
- Generalizes better (lower variance)

※ Inductive bias:

the set of assumptions or biases that a learning algorithm employs to make predictions on unseen data based on its training data


→ 모델의 일반화 가능성을 높이기 위한, 추가적인 가정

Dataset Splitting

To estimate generalization error, we need data unseen during training.


We split the data as

- Training set (60%)
 - Validation set (20%)
 - Test(Publication) set (20%)
- **Measure generalization accuracy by testing on data unused during training!**
 - **데이터의 양, 특성에 따라 적절한 분할 방법 사용!**



Cross Validation

k-fold Cross Validation



Regularization

Penalize complex models

- large estimate on parameters could increase model complexity
- Shrink model's complexity with additional loss term called "regularization term"
 - $E' = \text{error on data} + \lambda * \text{model complexity}$
 - If λ increases, variance decreases, but bias increases
- Regularize(Penalize) with N-norms (L1 : LASSO, L2 : Ridge, ElasticNet, ...)

General regularization formulation

$$\mathcal{L}(\mathbf{w}) + \lambda R(\mathbf{w})$$

λ : Regularization strength

$\mathbf{w}$: the model parameters or weights

$\mathcal{L}(\mathbf{w})$: Objective function or loss function

$R(\mathbf{w})$: Regularization term or regularizer or penalty

L2 Regularization

$$\text{Cost} = \underbrace{\sum_{i=0}^N (y_i - \sum_{j=0}^M x_{ij} W_j)^2}_{\text{Loss function}} + \lambda \underbrace{\sum_{j=0}^M W_j^2}_{\text{Regularization Term}}$$

공지사항

- 세션 후 뒤풀이 예정
 - 일시 : 1월 29일(목) 4주차 세션 후
 - 세션 : 대면 / 비대면 진행
 - 뒤풀이 : DL 세션과 합동 (미정)
- 일정이 있으신 분들은 미리 말씀해주시면 감사하겠습니다 :)



해당 자료는 Slack & KUBIG github에서 보실 수 있습니다 :)

2주차 과제는 1/21 수요일까지 github에 업로드 해 주시기 바랍니다!

2주차 과제 : KUBIG_2026_SPRING/Basic Study/ML/2주차
파일명 2026_1_ML_week2_{본인 이름}.ipynb 로 제출