




2026-1 BASIC STUDY ML 7주차

Clustering

SESSION LEADER: 21기 윤채영

2026.02.19



과제 우수자 발표

이서현 님

화면 공유해주시고
5분 이내로 설명 부탁드립니다 :)

Table of Contents

Clustering

Hard Clustering

Soft Clustering

Issues & Evaluation



Clustering

Keywords


**Supervised vs.
Unsupervised**

What is Clustering?

Clustering Methods

Supervised vs. Unsupervised

supervised learning




Supervised

Data: (x, y) pair (Input + Label)

Goal: 입력 x를 보고 정답 y를 예측하는 함수 $f(x)$ 를 학습

unsupervised learning



★ Unsupervised

Data: Only x (No Label !)

Goal: 데이터 x 자체의 숨겨진 구조나 패턴을 학습


What is Clustering?

Clustering refers to a very broad set of techniques for finding subgroups, or clustering clusters, in a data set.

When we cluster the observations of a data set, we seek to partition them into distinct groups so that the observations **within** each group are quite **similar** to each other, while observations in **different** groups are quite **different** from each other.

What is Clustering?

- **Clustering:** 유사한 특성을 가진 데이터끼리 그룹(Cluster)으로 묶는 작업
- **Objective Function:**
 - **Intra**-cluster Distance (군집 내 거리): **Minimize**
 - **Inter**-cluster Distance (군집 간 거리): **Maximize**
- **Applications:**
 - Customer Segmentation
 - Gene Expression
 - Image Compression




Clustering Methods: Hard vs. Soft

• Hard Clustering


- 각 데이터는 오직 하나의 군집에만 속함
- Assignment: $z_{ik} \in \{0, 1\}$ (Binary)
- Example: K-Means, Hierarchical, DBSCAN

• Soft Clustering (Probabilistic)

- 각 데이터가 여러 군집에 속할 확률을 가짐
- Assignment: $0 \leq z_{ik} \leq 1, \sum_k z_{ik} = 1$
- Example: Gaussian Mixture Models (GMM)



(a) hard clustering



(b) soft clustering



Hard Clustering

Keywords

K-Means


Hierarchical Clustering

DBSCAN (Density-based)

K-Means Clustering

Partitioning a data set into K distinct, non-overlapping clusters

To perform K-means clustering, we must first specify the desired number of clusters K ; then the K-means algorithm will assign each observation to exactly one of the K clusters.




K-Means Clustering

Algorithm:

1. Initialization: K개의 중심점(Centroid)을 랜덤하게 초기화
2. Assignment: 모든 데이터를 가장 가까운 중심점의 군집으로 할당
3. Update: 군집의 중심(평균 좌표)으로 Centroid 재계산
4. Repeat: 중심점이 더 이상 움직이지 않을 때까지 2~3번 반복

* 초기화 방식 보완: K-Means++



K-Means Clustering – Choosing K

K-Means의 단점: K를 사람이 미리 정해줘야 함 → K를 어떻게 결정할까?


(1) Elbow Method

: Within-Cluster Sum of Squares (WCSS / Inertia)가 급격히 줄어들다가 완만해지는 지점의 K를 선택

WCSS(Inertia):

$$J = \sum_{k=1}^K \sum_{x_i \in C_k}^{N_k} ||x_i - \mu_k||^2$$

- K : 전체 클러스터의 개수
- μ_k : k번째 클러스터의 중심점 (Centroid)
- $||x_i - \mu_k||^2$: data와 그 data가 속한 중심점 사이의 유클리드 거리의 제곱



K-Means Clustering – Choosing K

Elbow Method의 단점: 그래프에서 어디가 Elbow Point인지 애매할 때가 많음

(2) Silhouette Coefficient

: 실루엣 계수가 가장 높은 지점의 K를 선택

개별 데이터 i 에 대한 실루엣 계수: $s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$ → 모든 데이터 포인트의 평균값을 전체 Silhouette Score로 활용

1. 응집도($a(i)$): 나(i)와 같은 군집에 속하는 데이터들과의 평균 거리 → 작을수록 Good
2. 분리도($b(i)$): 나(i)와 가장 가까운 다른 군집과의 평균 거리 → 클수록 Good

[값 해석 방법]

- $s(i) \approx 1$ ($a(i) \ll b(i)$) : 내 군집과는 가깝고, 이웃 군집과는 멀 → 완벽한 군집화
- $s(i) \approx 0$ ($a(i) \approx b(i)$) : 내 군집과 이웃 군집 사이의 거리가 비슷함 → 두 군집의 경계선에 위치
- $s(i) \approx -1$ ($a(i) \gg b(i)$) : 내 군집보다 이웃 군집이 더 가까움 → 잘못된 군집에 할당됨

K-Means Clustering Example

Example

randomly pick the centroids of each cluster

	Word 1	Word 2
D1	5	3
D2	10	15
D3	15	12
D4	24	10
D5	30	45
D6	85	70
D7	71	80
D8	60	78
D9	55	52
D10	80	91

← **C1=(5,3)**
← **C2=(10,15)**

Example – Iteration 1

	Word 1	Word 2	D. from C1	D. from C2	Cluster
D1	5	3	0	13	
D2	10	15	13	0	
D3	15	12	13.45	5.83	
D4	24	10	20.25	14.87	
D5	30	45	48.88	36.06	
D6	85	70	104.35	93.01	
D7	71	80	101.41	89.14	
D8	60	78	93.01	80.43	
D9	55	52	70.01	58.26	
D10	80	91	115.62	103.32	

K-Means Clustering Example

Example – Iteration 1

C1=(5,3) *C2=(10,15)*

	Word 1	Word 2	D. from C1	D. from C2	Cluster
D1	5	3	0	13	1
D2	10	15	13	0	2
D3	15	12	13.45	5.83	2
D4	24	10	20.25	14.87	2
D5	30	45	48.88	36.06	2
D6	85	70	104.35	93.01	2
D7	71	80	101.41	89.14	2
D8	60	78	93.01	80.43	2
D9	55	52	70.01	58.26	2
D10	80	91	115.62	103.32	2

Example – Iteration 1

C1=(5,3) *C2=(10,15)*

	Word 1	Word 2	D. from C1	D. from C2	Cluster
D1	5	3	0	13	1
D2	10	15	13	0	2
D3	15	12	13.45	5.83	2
D4	24	10	20.25	14.87	2
D5	30	45	48.88	36.06	2
D6	85	70	104.35	93.01	2
D7	71	80	101.41	89.14	2
D8	60	78	93.01	80.43	2
D9	55	52	70.01	58.26	2
D10	80	91	115.62	103.32	2

← leave the centroid as it is
C1'=(5,3)

C2'=(47.78,50.33)
take the average of the 9 documents
=> (avg word1, avg word2)

K-Means Clustering Example

Example – Iteration 2

	Word 1	Word 2	D. from C1	D. from C2	Cluster
D1	5	3	0	63.80	
D2	10	15	13	51.73	
D3	15	12	13.45	50.44	
D4	24	10	20.25	46.82	
D5	30	45	48.88	18.56	
D6	85	70	104.35	42.10	
D7	71	80	101.41	37.68	
D8	60	78	93.01	30.25	
D9	55	52	70.01	7.41	
D10	80	91	115.62	51.89	

Example – Iteration 2

	Word 1	Word 2	D. from C1	D. from C2	Cluster
D1	5	3	0	63.80	1
D2	10	15	13	51.73	1
D3	15	12	13.45	50.44	1
D4	24	10	20.25	46.82	1
D5	30	45	48.88	18.56	2
D6	85	70	104.35	42.10	2
D7	71	80	101.41	37.68	2
D8	60	78	93.01	30.25	2
D9	55	52	70.01	7.41	2
D10	80	91	115.62	51.89	2

K-Means Clustering Example

Example – Iteration 2

	Word 1	Word 2	D. from C1	D. from C2	Cluster
D1	5	3	0	63.80	1
D2	10	15	13	51.73	1
D3	15	12	13.45	50.44	1
D4	24	10	20.25	46.82	1
D5	30	45	48.88	18.56	2
D6	85	70	104.35	42.10	2
D7	71	80	101.41	37.68	2
D8	60	78	93.01	30.25	2
D9	55	52	70.01	7.41	2
D10	80	91	115.62	51.89	2

$C1=(5,3)$
 $C2=(47.78,50.33)$

$C1'=(13.5,10.0)$
new centroid again
 $C2'=(63.5,69.3)$

Example – Iteration 3

	Word 1	Word 2	D. from C1	D. from C2	Cluster
D1	5	3	11.01	88.44	1
D2	10	15	6.10	76.25	1
D3	15	12	2.50	75.09	1
D4	24	10	10.50	71.28	1
D5	30	45	38.69	41.40	1
D6	85	70	93.34	21.51	2
D7	71	80	90.59	13.04	2
D8	60	78	82.38	9.35	2
D9	55	52	59.04	19.30	2
D10	80	91	104.80	27.24	2

$C1=(13.5,10.0)$
 $C2=(63.5,69.3)$

$C1'=(16.8,17.0)$
 $C2'=(70.2,74.2)$

calculate distance again
-> if there's an update => update ... repeat until there is no update anymore

K-Means Clustering Example

Example – Iteration 4


	Word 1	Word 2	D. from C1	D. from C2	Cluster
D1	5	3	18.31	96.54	1
D2	10	15	7.09	84.43	1
D3	15	12	5.31	83.16	1
D4	24	10	10.04	79.10	1
D5	30	45	30.96	49.69	1
D6	85	70	86.37	15.38	2
D7	71	80	83.11	5.85	2
D8	60	78	74.75	10.88	2
D9	55	52	51.81	26.91	2
D10	80	91	97.32	19.45	2

no update anymore !! => done!

C1=(16.8,17.0)
C2=(70.2,74.2)


C1'=(16.8,17.0)
C2'=(70.2,74.2)

Example – Final output



Hierarchical Clustering

Hierarchical clustering is an alternative approach which does not require that we commit to a particular choice of K. Hierarchical clustering has an added advantage over K-means clustering in that it results in an attractive tree-based representation of the observations, called a dendrogram.



Hierarchical Clustering

: 개체들을 가까운 거리 순으로 묶어 계층적인 트리 구조를 형성하는 방식


[두 가지 Approach]

1. Agglomerative (Bottom-up)

- 시작: 모든 데이터 하나하나가 개별 클러스터 (N Clusters)
- 과정: 가장 가까운 두 클러스터를 반복적으로 병합 (Merge)
- 종료: 모든 데이터가 하나의 거대한 클러스터가 됨 (1 Cluster)


2. Divisive (Top-down)

- 시작: 모든 데이터가 하나의 거대한 클러스터 (1 Cluster)
- 과정: 가장 이질적인 데이터를 분리해 나감 (Split)



Agglomerative Hierarchical Clustering

(1) 시작 전, 모든 개체들 간 거리(distance)나 유사도(similarity)가 계산되어 있어야 함




	A	B	C	D
A		20	7	2
B			10	25
C				3
D				

Agglomerative Hierarchical Clustering

(2) 거리가 가까운 관측치들끼리 차례대로 군집으로 묶음 → A와 D를 하나의 군집으로 묶기


*y축은 두 군집 간 거리(비유사도)를 의미



	A	B	C	D
A		20	7	2
B			10	25
C				3
D				

Agglomerative Hierarchical Clustering


- (3) A와 D를 하나의 군집으로 묶은 후 거리행렬 업데이트 (군집-개체, 혹은 군집-군집 간 거리 계산)
→ AD와 C를 하나의 군집으로 묶기



	AD	B	C	
AD		20	3	
B			10	
C				

Agglomerative Hierarchical Clustering


(3) AD와 C를 하나의 군집으로 묶은 후 거리행렬 업데이트 → ADC와 B를 하나의 군집으로 묶기



	ADC	B		
ADC		10		
B				

Agglomerative Hierarchical Clustering

(4) 분석 대상 관측치가 하나도 없으면 학습이 종료됨




	AD CB			
AD CB				

Hierarchical Clustering


Types of Linkage

Linkage	Description
Complete	Maximal intercluster dissimilarity. Compute all pairwise dissimilarities between the observations in cluster A and the observations in cluster B, and record the <i>largest</i> of these dissimilarities.
Single	Minimal intercluster dissimilarity. Compute all pairwise dissimilarities between the observations in cluster A and the observations in cluster B, and record the <i>smallest</i> of these dissimilarities. Single linkage can result in extended, trailing clusters in which single observations are fused one-at-a-time.
Average	Mean intercluster dissimilarity. Compute all pairwise dissimilarities between the observations in cluster A and the observations in cluster B, and record the <i>average</i> of these dissimilarities.
Centroid	Dissimilarity between the centroid for cluster A (a mean vector of length p) and the centroid for cluster B. Centroid linkage can result in undesirable <i>inversions</i> .


Single linkage




Complete linkage



Centroid linkage






Average linkage




 Centroid of each cluster

Dendrogram

The number of clusters is given by the **number of vertical lines crossed** when a horizontal line cuts the dendrogram.



적절한 높이 선택 방법:

덴드로그램을 봤을 때, 가로선 없이 **세로로 길게** 뻗어 있는 구간이 있음


이 긴 구간은, 데이터들이 '꽤 오랫동안 합쳐지지 않고 자기들끼리 잘 뭉쳐 있었다'는 뜻

이 **긴 세로선의 중간 지점**이 '데이터가 가장 자연스럽게 나뉘는 최적의 군집 개수'를 구할 수 있는 적절한 높이

DBSCAN (Density-based spatial clustering of applications with noise)

K-Means의 한계를 보완하기 위해 등장한 방법

1. 원형(Spherical)이 아닌 기하학적 패턴을 가진 클러스터를 잘 못 잡아냄
2. 군집의 개수 K 를 미리 정해줘야 함
3. Noise(Outlier)에 취약함



DBSCAN: 데이터가 밀집되어 있는 집합을 하나의 클러스터로 간주하자 !


2개의 Hyperparameter: **Epsilon (ϵ) – 반경** & **MinPts – 최소 데이터 개수**

→ “어떤 점 p 에서 반경 ϵ 내에 MinPts개 이상의 점이 있다면,
 p 를 ‘Core Point’로 설정하고 하나의 클러스터로 묶자 !”

DBSCAN (Density-based spatial clustering of applications with noise)

[Algorithm]

- 임의의 데이터 포인트 p 선택
- p 로부터 Eps 거리 내에 있는 모든 포인트를 찾음
 - Eps 거리 내 데이터 포인트의 개수가 MinPts 이상: p 를 **Core Point**로 하는 새로운 클러스터 생성
 - Eps 거리 내 데이터 포인트의 개수가 MinPts 미만: 다른 클러스터의 Core Point를 포함하고 있다면 해당 클러스터의 **Border Point**로서 같이 묶어줌
- 클러스터 내에 다른 군집의 Core Point가 있다면, 그 점을 Core Point로 하는 클러스터도 동일한 군집으로 간주
- 데이터셋의 모든 점에 대해서 1~3의 과정을 반복
- 어느 Cluster에도 포함되지 않는 데이터 포인트는 **Noise Point** 처리





Soft Clustering


Keywords

**Gaussian Mixture Models
(GMM)**

EM Algorithm

Gaussian Mixture Models (GMM)

idea) 복잡한 데이터의 분포를 [가우시안 분포(정규분포)]를 여러 개 혼합]해서 근사하자 !



즉, 데이터가 K 개의 Gaussian Distribution에서 생성되었다고 가정함
따라서, '데이터가 어떤 분포에서 왔는지 추적하는 방식'으로 군집을 찾는 것

Gaussian Mixture Models (GMM)

[PDF of GMM]


$$p(x) = \sum_{k=1}^K \pi_k \mathcal{N}(x | \mu_k, \Sigma_k)$$

π_k : mixture weight

$\mathcal{N}(x | \mu_k, \Sigma_k)$: probability density of under the kth Gaussian

[Soft Clustering based on GMM]

$$P(\text{Cluster } k | x) = \frac{\pi_k \mathcal{N}(x | \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j \mathcal{N}(x | \mu_j, \Sigma_j)}$$



EM Algorithm (Expectation–Maximization)

$$p(x) = \sum_{k=1}^K \pi_k \mathcal{N}(x | \mu_k, \Sigma_k) \quad \rightarrow \quad \text{parameter } \pi, \mu, \Sigma \text{ 계산 필요}$$

Dilemma:

GMM의 PDF를 완성하려면? → 각 Gaussian에 어떤 데이터들이 속하는지 알아야 함
각 데이터가 속한 Gaussian을 알려면? → 각 Gaussian의 위치와 모양(μ, Σ)을 알아야 함
즉, ‘Circular Dependency’ 상황



Solution) **EM Algorithm** !

EM Algorithm (Expectation–Maximization)

[Algorithm]

1. Initialization: 랜덤하게 산봉우리(분포) 배치.

2. **E-Step (Expectation)**: 현재 분포를 기준으로 데이터의 Log Joint Likelihood의 평균을 계산

* Baum's Q-Function: $Q(\theta'|\theta) = \mathbb{E}_{\mathcal{Z}}[\log P(\mathcal{D}, \mathcal{Z}|\theta')|\mathcal{D}, \theta]$

3. **M-Step (Maximization)**: 앞서 계산한 Likelihood가 Maximize 되도록 파라미터(π, μ, Σ)를 업데이트

* $\hat{\theta} = \operatorname{argmax}_{\theta'} Q(\theta'|\theta)$

<MLE>


$$\pi_k \leftarrow \frac{\sum_t w_k^t}{N}$$

$$\mu_k \leftarrow \frac{\sum_t w_k^t x^t}{\sum_t w_k^t}$$

$$\Sigma_k \leftarrow \frac{\sum_t w_k^t x^t (x^t)^\top}{\sum_t w_k^t} - \mu_k \mu_k^\top$$


$$w_k^t \equiv P(\text{Cluster } k|x^t, \theta^i) = \frac{\pi_k \mathcal{N}(x|\mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j \mathcal{N}(x|\mu_j, \Sigma_j)}$$

4. Repeat 2~3 until convergence



K-Means vs. GMM

	K-Means Clustering	Gaussian Mixture Models (GMM)
군집화 유형	Hard Clustering	Soft Clustering
군집 모양	원형	타원형 (공분산에 따라 모양 변형 가능)
파라미터	중심점 μ	π, μ, Σ
계산 속도	빠름 (대용량 데이터에 적합)	느림 (복잡한 연산 필요)
활용	단순한 분류, 데이터 전처리	분포 추정, 이상치 탐지, 중첩된 데이터



K-Means는 GMM의 특수한 형태 !

GMM w/ "모든 군집이 완벽한 원형이고(동일한 공분산), 한 데이터는 한 군집에만 속한다(Hard)"의 제약
= K-Means



Issues & Evaluation

Keywords

Issues in Clustering

Evaluation Metrics

After Clustering

The Curse of Dimensionality

Problem:

Clustering에서는 보통 **거리(Distance)**를 기반으로 유사도를 판단함
하지만 차원(Feature)이 커질수록, 데이터 간의 거리가 모두 멀어짐
→ 즉, '**거리의 변별력(Discriminatory Power)**'이 사라짐

Solution:

Dimensionality Reduction(PCA, t-SNE, UMAP 등)을 먼저 적용
→ 중요 Feature만 추출 후 클러스터링 수행.

Outliers & Scaling

Problem 1: Outliers


K-Means의 중심(μ)은 평균값이므로, 극단적인 이상치 하나가 전체 군집을 망가뜨림

→ Solution: 전처리 과정에서 **이상치 제거**


Problem 2: Scaling

Feature A: 연봉 (0 ~ 1억), Feature B: 나이 (0 ~ 100)라고 할 때, 거리 측정 시 연봉이 값을 지배해버림

→ Solution: **Standardization** (MinMax / Standard Scaler)



(A): Undesirable clusters



(B): Ideal clusters

Evaluation Metrics

Internal Evaluation (Label이 없는 경우)

1. Inertia

- "각 데이터가 자기가 속한 군집의 중심과 얼마나 가까운가?"
- 값이 작을수록 좋음 (군집 내 데이터가 똬똬 뭉침)
- Elbow Method의 기준

$$\sum_{k=1}^K \sum_{x_i \in C_k} ||x_i - \mu_k||^2$$

2. Silhouette Score

- "우리끼린 가깝고(a), 다른 군집이랑은 멀리 있는가(b)?"
- 1에 가까울수록 좋음

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$

External Evaluation (Label이 있는 경우)

1. Adjusted Rand Index (ARI)

- 모든 가능한 데이터 포인트 짝(Pair)들을 일일이 확인
- 정답에서의 관계와 Clustering에서의 관계가 동일한지 확인
- 범위: -1~1
→ 0: 무작위 수준 / 1: 정답과 완벽하게 일치

2. Normalized Mutual Information (NMI)

- “Clustering 결과가 정답을 예측하는 데 얼마나 많은 정보(힌트)를 제공해 주는가?”를 측정
- 범위: 0 (무정보) ~ 1 (완벽)

After Clustering – Profiling

클러스터링 결과는 ‘숫자(0~K)’로만 알 수 있음


→ Insight를 도출하려면 '이름 붙이기(Naming / Persona)' 작업이 별도로 필요

클러스터별 데이터의 특성을 보고, 사람이 직접 context를 부여

1. 통계적 Profiling: 각 군집별로 Feature들의 평균값을 구해 전체 평균과 비교

2. Radar Chart로 시각화

3. 1과 2를 통해 파악한 특징을 기반으로 이름을 붙여줌 (Persona 부여)





해당 자료는 Slack & KUBIG github에서 보실 수 있습니다 :)
2/27(금) 19:30, '왕십리 공간나인'에서 KUBIG Contest가 예정되어 있습니다.

7주차 과제 : KUBIG_2026_SPRING/Basic Study/ML/7주차
파일명 2026_1_ML_week7_{본인 이름}.ipynb 로 제출