

Parameter-Efficient Transfer Learning for NLP

저자

- Neil Houlsby, Andrei Giurgiu, Stanisław Jastrzebski, Bruna Morrone, Quentin de Laroussilhe, Andrea Gesmundo, Mona Attariyan, Sylvain Gelly

링크

- <https://arxiv.org/pdf/1902.00751>

1. Introduction

- 전체 미세 조정의 매개변수 비효율성: 기존의 미세 조정 방식은 새로운 태스크가 추가될 때마다 수억 개의 파라미터를 가진 모델 전체를 복사하여 저장해야 하므로, 관리해야 할 태스크가 많은 환경에서 저장 공간과 효율성 문제가 심각함.
- 어댑터 모듈을 통한 대안 제시: 사전 학습된 가중치는 고정(Frozen)한 채, 레이어 사이에 아주 적은 수의 학습 가능한 파라미터만 가진 어댑터 모듈을 삽입하여 각 태스크에 적응시키는 새로운 전이 학습 전략을 제안함.
- 압축성과 확장성의 동시 확보: 태스크당 모델 파라미터의 단 3~3.6%만 추가하고도 전체 미세 조정 대비 성능 차이를 0.4% 이내로 유지했으며, 기존 지식을 잊어버리지 않고 새로운 태스크를 점진적으로 추가할 수 있는 구조를 증명함.
- 매개변수 효율적 전이 학습(PEFT)의 실효성을 최초로 입증하며, 하나의 공유 모델로 수많은 하위 작업을 처리해야 하는 실제 서비스 환경에 최적화된 아키텍처를 제시함.

2. Adapter tuning for NLP

- 효율적 튜닝 전략: 성능 저하 없이 데이터셋 동시 접근 없이도 순차적 학습이 가능하며, 태스크당 추가 파라미터를 최소화함.
- 어댑터 삽입 및 고정: 모델 본체(Frozen)는 건드리지 않고 무작위 초기화된 작은 어댑터 레이어만 삽입하여 독립적으로 학습함.
- 병목 구조와 초기화: 파라미터를 줄이는 병목(Bottleneck) 설계와 기존 지식 파괴를 막는 항등 함수(Identity) 초기화로 학습 안정성을 확보함.

- 실무적 확장성: 태스크가 늘어나도 모델 크기 증가가 매우 느려 대규모 시스템 관리에 유리하며, 불필요한 어댑터는 무시되는 유연성을 가짐.

2.1) Instantiation for Transformer Networks




Figure 2. Architecture of the adapter module and its integration with the Transformer. **Left:** We add the adapter module twice to each Transformer layer: after the projection following multi-headed attention and after the two feed-forward layers. **Right:** The adapter consists of a bottleneck which contains few parameters relative to the attention and feedforward layers in the original model. The adapter also contains a skip-connection. During adapter tuning, the green layers are trained on the downstream data, this includes the adapter, the layer normalization parameters, and the final classification layer (not shown in the figure).

- 트랜스포머의 각 레이어 내 셀프 어텐션과 피드포워드 서브 레이어 직후, 스킵 커넥션 합산 전 위치에 총 2개의 어댑터를 직렬로 삽입함.
- 원래 차원(d)을 저차원(m)으로 줄였다가 다시 복구하는 병목(Bottleneck) 구조를 통해 추가 파라미터를 모델 전체의 0.5~8% 수준으로 극소화함.
- 어댑터 내부의 스킵 커넥션과 제로 초기화 전략을 사용하여 학습 초기 모델이 기존 성능을 그대로 유지하는 항등 함수(Identity function)로 동작하게 함.
- 어댑터와 함께 태스크별 레이어 정규화 파라미터를 학습시켜 효율성을 높였으며, 정규화만 단독으로 학습시키는 것보다 어댑터를 병행하는 것이 성능에 필수적임을 입증함.

3. Experiments

- 어댑터가 텍스트 관련 작업에서 매개변수 효율적인 전이 학습을 달성함을 증명함.
- GLUE 벤치마크 실험 결과, 어댑터 튜닝은 BERT 전체 미세 조정과 비교해 성능 차이가 0.4% 이내에 불과하면서도, 학습에 사용되는 매개변수 수는 미세 조정의 3% 수준에 머물렀음.
- 17개의 추가적인 공개 분류 작업과 SQuAD 질의응답 데이터셋에서도 동일하게 확인됨.
- 분석 결과, 어댑터 기반 튜닝은 네트워크의 상위 레이어에 자동으로 집중하여 학습을 진행하는 특성을 보임.

3.1) Experimental settings

- 기본 모델 및 구조: 사전 학습된 BERT를 기반으로 하며, CLS 토큰에 선형 레이어를 붙여 분류를 수행하는 표준 방식을 채택함.

- 학습 최적화 전략: Adam 옵티마이저와 Linear learning rate decay(학습률 점진적 감소)를 사용하며, TPU 환경에서 정교한 하이퍼파라미터 스위치를 통해 최적의 모델을 선정함.
- 비교 대조군 설정: 기존의 표준인 전체 미세 조정(Full fine-tuning)을 주요 비교군으로 설정하여 성능 우위를 검증함.
- 핵심 목표 재확인: 태스크가 N개로 늘어남에 따라 파라미터 저장 용량이 N배로 폭증하는 기존 미세 조정의 한계를 극복하고, 단일 모델 크기(1x)에 근접한 효율성으로 동등한 성능을 내는 것을 목표로 함.

3.2) GLUE Benchmark

	Total num params	Trained params / task	CoLA	SST	MRPC	STS-B	QQP	MNLI _m	MNLI _{mm}	QNLI	RTE	Total
BERT _{LARGE}	9.0×	100%	60.5	94.9	89.3	87.6	72.1	86.7	85.9	91.1	70.1	80.4
Adapters (8-256)	1.3×	3.6%	59.5	94.0	89.5	86.9	71.8	84.9	85.1	90.7	71.5	80.0
Adapters (64)	1.2×	2.1%	56.9	94.2	89.6	87.3	71.8	85.3	84.6	91.4	68.8	79.6

Table 1. Results on GLUE test sets scored using the GLUE evaluation server. MRPC and QQP are evaluated using F1 score. STS-B is evaluated using Spearman's correlation coefficient. CoLA is evaluated using Matthew's Correlation. The other tasks are evaluated using accuracy. Adapter tuning achieves comparable overall score (80.0) to full fine-tuning (80.4) using $1.3\times$ parameters in total, compared to $9\times$. Fixing the adapter size to 64 leads to a slightly decreased overall score of 79.6 and slightly smaller model.

- 실험 환경 및 튜닝: $BERT_{LARGE}$ (330M 파라미터)를 기반으로 학습률과 에포크를 탐색했으며, 병목 구간의 크기인 'Adapter size'를 주요 하이퍼파라미터로 설정하여 최적화를 진행함.
- 성능 및 효율성 대조: 어댑터 방식(80.0점)은 전체 미세 조정(80.4점)과 비교해 점수 차이가 0.4점에 불과하여 성능 저하가 거의 없음을 입증함.
- 데이터셋 규모에 따른 적응: 데이터셋이 큰 MNLI는 큰 어댑터(256)를, 작은 RTE는 작은 어댑터(8)를 선택하는 등 태스크 규모에 따라 유연하게 대응함.
- 압도적인 저장 공간 절약: 9개의 태스크를 수행할 때 기존 방식은 모델 9개 분량(9x)의 저장 공간이 필요하지만, 어댑터는 본체 하나와 작은 모듈들을 합쳐 단 1.3배(1.3x)의 용량만으로 충분함.

3.3) Additional Classification Tasks

Dataset	No BERT baseline	BERT _{BASE} Fine-tune	BERT _{BASE} Variable FT	BERT _{BASE} Adapters
20 newsgroups	91.1	92.8 $\pm$ 0.1	92.8 $\pm$ 0.1	91.7 $\pm$ 0.2
Crowdfower airline	84.5	83.6 $\pm$ 0.3	84.0 $\pm$ 0.1	84.5 $\pm$ 0.2
Crowdfower corporate messaging	91.9	92.5 $\pm$ 0.5	92.4 $\pm$ 0.6	92.9 $\pm$ 0.3
Crowdfower disasters	84.9	85.3 $\pm$ 0.4	85.3 $\pm$ 0.4	84.1 $\pm$ 0.2
Crowdfower economic news relevance	81.1	82.1 $\pm$ 0.0	78.9 $\pm$ 2.8	82.5 $\pm$ 0.3
Crowdfower emotion	36.3	38.4 $\pm$ 0.1	37.6 $\pm$ 0.2	38.7 $\pm$ 0.1
Crowdfower global warming	82.7	84.2 $\pm$ 0.4	81.9 $\pm$ 0.2	82.7 $\pm$ 0.3
Crowdfower political audience	81.0	80.9 $\pm$ 0.3	80.7 $\pm$ 0.8	79.0 $\pm$ 0.5
Crowdfower political bias	76.8	75.2 $\pm$ 0.9	76.5 $\pm$ 0.4	75.9 $\pm$ 0.3
Crowdfower political message	43.8	38.9 $\pm$ 0.6	44.9 $\pm$ 0.6	44.1 $\pm$ 0.2
Crowdfower primary emotions	33.5	36.9 $\pm$ 1.6	38.2 $\pm$ 1.0	33.9 $\pm$ 1.4
Crowdfower progressive opinion	70.6	71.6 $\pm$ 0.5	75.9 $\pm$ 1.3	71.7 $\pm$ 1.1
Crowdfower progressive stance	54.3	63.8 $\pm$ 1.0	61.5 $\pm$ 1.3	60.6 $\pm$ 1.4
Crowdfower US economic performance	75.6	75.3 $\pm$ 0.1	76.5 $\pm$ 0.4	77.3 $\pm$ 0.1
Customer complaint database	54.5	55.9 $\pm$ 0.1	56.4 $\pm$ 0.1	55.4 $\pm$ 0.1
News aggregator dataset	95.2	96.3 $\pm$ 0.0	96.5 $\pm$ 0.0	96.2 $\pm$ 0.0
SMS spam collection	98.5	99.3 $\pm$ 0.2	99.3 $\pm$ 0.2	95.1 $\pm$ 2.2
Average	72.7	73.7	74.0	73.3
Total number of params	—	17 $\times$	9.9 $\times$	1.19 $\times$
Trained params/task	—	100%	52.9%	1.14%

Table 2. Test accuracy for additional classification tasks. In these experiments we transfer from the BERT_{BASE} model. For each task and algorithm, the model with the best validation set accuracy is chosen. We report the mean test accuracy and s.e.m. across runs with different random seeds.

- 어댑터가 작고 성능이 우수한 모델을 생성함을 입증하기 위해 추가적인 17개의 공개 텍스트 분류 작업을 테스트함.
- BERT vs AutoML: 수만 개의 모델 아키텍처를 탐색한 AutoML 결과보다 BERT 기반 모델들이 평균적으로 더 우수한 성능을 보여, 실험의 베이스라인 자체가 매우 강력함을 입증함.
- Variable Fine-tuning: 모델 전체가 아닌 상위 일부 레이어만 학습시키는 방식과 비교했을 때도, 어댑터는 훨씬 적은 파라미터만 사용하면서 대등하거나 더 나은 성능을 보여줌. (Since some of the datasets are small, fine-tuning the entire network may be sub-optimal. Therefore, we run an additional baseline: variable fine tuning_fine-tune only the top n layers, and freeze the remainder.)
- 성능 비교 (BERT / Adapter / Variable FT): 17개의 다양한 태스크에서 어댑터는 전체 미세 조정 대비 성능 차이를 0.4%로 유지함. 이는 GLUE 벤치마크와 일관된 결과로 어댑터의 범용성을 뒷받침함.
- 저장 공간 절약: 17개 태스크 기준, 기존 방식은 모델 17개 분량(17x)이 필요하고 효율적이라던 가변 미세 조정도 9.9배(9.9x)가 필요한 반면, 어댑터는 단 1.19배(1.19x)의 저장 공간만 사용하여 극강의 효율성을 달성함.

3.4) Parameter/Performance trade-off




Figure 3. Accuracy versus the number of trained parameters, aggregated across tasks. We compare adapters of different sizes (orange) with fine-tuning the top n layers, for varying n (blue). The lines and shaded areas indicate the 20th, 50th, and 80th percentiles across tasks. For each task and algorithm, the best model is selected for each point along the curve. For GLUE, the validation set accuracy is reported. For the additional tasks, we report the test-set accuracies. To remove the intra-task variance in scores, we normalize the scores for each model and task by subtracting the performance of full fine-tuning on the corresponding task.





Figure 4. Validation set accuracy versus number of trained parameters for three methods: (i) Adapter tuning with an adapter sizes 2^n for $n = 0 \dots 9$ (orange). (ii) Fine-tuning the top k layers for $k = 1 \dots 12$ (blue). (iii) Tuning the layer normalization parameters only (green). Error bars indicate ± 1 s.e.m. across three random seeds.

- 상위 k 개 레이어만 학습시키는 방식 및 레이어 정규화(Layer Norm)만 학습시키는 방식과 어댑터의 효율성을 대조함.
- GLUE 전체 성능: 어댑터(80.0점)는 전체 미세 조정(80.4점)과 대등한 성능을 내면서도, 9개 작업 처리 시 저장 공간을 9배에서 1.3배로 획기적으로 줄임.
- MNLI 상세 비교: 상위 레이어만 학습할 때(9M 파라미터, 77.8%)보다 어댑터가 파라미터는 4.5배 적게 쓰면서 성능은 5.9%p 더 높음.
- CoLA 및 효율성: 레이어 정규화만 튜닝하면 성능이 3.5% 급락하지만, 어댑터는 모델의 0.5~5% 파라미터만으로 최첨단 성능을 유지하며 압도적인 효율을 증명함.

3.5) SQuAD Extractive Question Answering



- 텍스트 분류를 넘어 복잡한 문맥 파악이 필요한 SQuAD 질의응답(QA) 작업에서도 어댑터의 실효성을 입증함.
- SQuAD 성능 비교: 크기 64의 어댑터(파라미터 2%)가 F1 90.4%를 기록하며, 전체 미세 조정(90.7%)과 대등한 최첨단 성능을 유지함. 단 0.1%의 파라미터(Size 2)만 추가하고도 89.9%의 높은 F1 점수를 기록하여, 매우 적은 자원으로도 복잡한 문제 해결이 가능함을 보여줌.

3.6) Analysis and Discussion




Figure 6. Left, Center: Ablation of trained adapters from continuous layer spans. The heatmap shows the relative decrease in validation accuracy to the fully trained adapted model. The y and x axes indicate the first and last layers ablated (inclusive), respectively. The diagonal cells, highlighted in green, indicate ablation of a single layer’s adapters. The cell in the top-right indicates ablation of all adapters. Cells in the lower triangle are meaningless, and are set to 0%, the best possible relative performance. **Right:** Performance of BERT_{BASE} using adapters with different initial weight magnitudes. The x-axis is the standard deviation of the initialization distribution.

- 상위 레이어 자동 집중: 하위 레이어 어댑터는 제거해도 성능에 지장이 거의 없었으나, 상위 레이어 어댑터는 성능 유지에 핵심적인 역할을 함. 이는 어댑터가 각 태스크에 고유한 상위 수준 특징을 학습하는 데 스스로 집중함을 보여줌.
- 초기화 및 크기의 견고성: 가중치 초기화 표준편차가 10^{-2} 이하인 조건과 다양한 어댑터 크기(8~256)에서 모두 안정적인 성능을 기록하여, 하이퍼파라미터 변화에 매우 강한 구조임을 입증함.
- 아키텍처의 단순성: 정규화 추가나 병렬 삽입 등 복잡한 변형들을 테스트했으나 성능 차이가 미미하여, 단순하면서도 효율적인 기본 병목(Bottleneck) 구조가 최적임을 확인함.

4. Related Work

- Pre-trained Representations (사전 학습 표현): ELMo 등 기존 방식은 내부 층의 정보를 읽기만(Read) 하지만, 어댑터는 내부 층에 직접 정보를 쓰고(Write) 네트워크 전체의 특징 처리 과정을 재구성하여 더 능동적인 전이 학습을 수행함.
- Fine-tuning (미세 조정): 태스크마다 모델 파라미터 전체를 새로 저장해야 하는 기존 미세 조정의 비효율성을 해결함. 본체 가중치는 고정해 작업별 설계 없이도 매개변수 효율성을 유지하며 최신 성능(SOTA)에 근접함.
- Multi-task Learning (다중 작업 학습): 모든 태스크에 동시에 접근하여 학습해야 하는 MTL의 제약과 달리, 어댑터는 각 태스크를 독립적으로 학습하면서도 단일 공유 모델을 통해 모든 문제를 해결하는 효율을 달성함.
- Continual Learning (연속 학습): 새로운 학습 시 이전 지식을 잊어버리는 치명적 망각(Catastrophic forgetting) 문제가 전혀 없음. 기존 가중치를 고정하므로 완벽한 기억을 보장하며, 태스크 추가 시 파라미터 증가량도 매우 적음.
- Transfer Learning in Vision (시각 지능 전이 학습): 모델 크기를 11%나 증가시키는 기존 비전 분야의 어댑터보다 훨씬 작은 0.5~5%의 파라미터만으로 성능을 유지함. 이는 병목(Bottleneck) 구조를 통해 극강의 압축 효율을 달성했기 때문임.