


Chain-of-Thought Prompting Elicits Reasoning in Large Language Models

1. Introduction

대형 언어 모델(LLM)은 모델 규모 증가에 따라 다양한 자연어 처리 과제에서 성능 향상을 보였지만, **여러 단계 추론이 필요한 문제**에서는 여전히 한계를 보임. 특히 산술 문제나 상식 추론과 같은 reasoning task는 단순한 텍스트 생성 능력만으로 해결되기 어렵다는 한계가 존재



기존 접근 방식



기존 접근 방식

1. 중간 추론 과정(rationale)을 포함하여 모델을 학습시키는 방법
→ 높은 품질의 추론 데이터 구축 비용이 큼
2. 일반적인 few-shot prompting은 입력-출력 예시만 제공하기 때문에 **복잡한 reasoning 능력을 충분히 끌어내지 못함**

본 논문은 이러한 문제를 해결하기 위해 Chain-of-Thought Prompting(CoT)을 제안
이는 few-shot 예시를 단순한 정답 제시가 아니라, 문제 해결에 필요한 **중간 추론 단계**까지
포함하도록 구성하는 방법. 저자들은 충분히 큰 규모의 언어 모델에서 CoT가 자연스럽게
reasoning 능력을 유도하며, 별도의 파인튜닝 없이도 성능을 크게 향상시킬 수 있음을 보
임.

2. Method

Chain-of-Thought Prompting의 기본 구조는 기존 few-shot prompting을 다음과 같이
확장

기존 형태: (x, y)

제안 방식: (x, r, y)

여기서

- x : 입력 문제
- r : 자연어 기반의 중간 추론 과정 (chain of thought)
- y : 최종 정답

→ 즉, 모델은 정답을 바로 생성하는 대신 **단계적 reasoning sequence**를 먼저 생성한 후
최종 결과를 출력

이 접근의 핵심 목적은 복잡한 문제를 여러 단계로 분해하여 해결하도록 유도. 중간 추론 단
계는 모델이 추가적인 계산을 수행하도록 만들며, 생성된 reasoning 과정은 모델의 판단 근
거를 해석할 수 있는 단서를 제공함. 또한 이러한 방식은 별도의 학습 없이 기존 대형 언어 모
델에 프롬프트만 추가하여 적용할 수 있다는 장점이 있음

3. Experiments


저자들은 Chain-of-Thought Prompting의 효과를 세 가지 유형의 reasoning 과제에서
평가

Arithmetic reasoning에서는 GSM8K, SVAMP, MAWPS 등의 수학 word problem 데이터셋을 사용

GPT-3, LaMDA, PaLM 등 다양한 규모의 언어 모델을 비교한 결과, CoT는 특히 대형 모델에서 성능 향상을 보임. 작은 모델에서는 오히려 성능이 감소하거나 논리적으로 맞지 않는 추론을 생성하는 경우가 많았음.

Commonsense reasoning 실험에서는 CSQA, StrategyQA, Date Understanding, Sports Understanding, SayCan 등의 데이터셋을 사용

모델 규모가 증가할수록 기본 성능이 향상되었으며, CoT를 적용하면 추가적인 성능 개선이 나타남. 특히 StrategyQA와 같은 다단계 추론 문제에서 기존 방법 대비 큰 향상을 보임.



Symbolic reasoning에서는 문자열 조작과 상태 추과 같은 단순하지만 구조적 추론이 필요한 과제를 사용 CoT는 학습 시 보지 못한 더 긴 입력에 대해서도 일반화 성능을 향상시키는 경향을 보임.

추가적으로 수행된 ablation 연구에서는 단순히 수식만 생성하거나, 정답 이후에 reasoning을 생성하는 방식은 효과가 제한적이었으며, **자연어 기반의 순차적 추론 과정 자체가 핵심 요소**임을 확인

4. Discussion

실험 결과는 Chain-of-Thought reasoning이 **모델 규모 증가에 따라 나타나는 emergent ability**임을 보여줌

→ 일정 규모 이상의 모델에서만 의미 있는 성능 향상이 나타났으며, 언어 모델이 semantic understanding과 논리적 추론 능력을 점진적으로 학습한다는 사실을 알 수 있음

CoT 과정에서 생성된 추론 과정이 항상 정확하다고 보장할 수 없으며, reasoning이 실제 내부 계산을 반영하는지에 대해서는 여전히 문제로 남아있음. 또한 대형 모델 의존성으로 인해 실제 응용에서 비용 문제가 존재

5. Conclusion

본 논문은 Chain-of-Thought Prompting이라는 단순한 프롬프트 설계만으로도 대형 언어 모델의 추론 능력을 크게 향상시킬 수 있음을 실험적으로 보여줌. 특히 arithmetic, commonsense, symbolic reasoning 전반에서 일관된 성능 향상이 관찰되었으며, 이러한 능력은 모델 규모 증가에 따라 나타나는 특성으로 해석됨

→ 결과적으로 CoT는 추가 학습 없이 LLM의 잠재적 reasoning 능력을 확장할 수 있는 효과적인 접근법