

REACT: SYNERGIZING REASONING AND ACTING IN LANGUAGE MODELS

저자

- Shunyu Yao, Jeffrey Zhao, Dian Yu, Nan Du, Izhak Shafran, Karthik Narasimhan, Yuan Cao (Princeton University, Google Research Brain team)

링크

- <https://arxiv.org/pdf/2210.03629>

1. Introduction

- Synergy of Reason & Act: 인간이 요리할 때처럼 진행 상황을 언어로 추적(Reason)하고 필요한 정보를 검색(Act)하는 과정을 교차함. 단순히 생각만 하거나 행동만 하는 기존 방식을 넘어, 두 과정이 서로를 보충하며 불확실한 상황에서도 견고한 의사결정을 수행함.
- Overcoming CoT Limits: 내부 지식에만 의존하는 기존 '사고의 사슬(CoT)'의 정적인 블랙박스 구조를 해결함. 외부 세계(Wikipedia 등)와 단절되어 발생하는 사실 환각(Hallucination)과 오류 전파 문제를 외부 정보를 실시간으로 통합함으로써 차단함.
- Dynamic Planning: 고수준의 목표를 추상적으로만 설정하는 기존 행동 모델과 달리, 언어 모델을 작업 기억(Working Memory)으로 활용함. 상황에 따라 계획을 유도, 유지, 수정하는 '행동을 위한 추론(Reason to Act)'을 통해 복잡한 환경에 대응함.
- Few-shot Efficiency: 수만 개의 데이터를 학습해야 하는 기존 모방 학습이나 강화 학습(RL)과 달리, 단 1~2개의 예시(In-context examples)만으로도 ALFWorld(34%↑) 및 WebShop(10%↑) 등에서 최신 성능(SOTA)을 압도함.
- Interpretability & Trust: 모델의 내부 지식과 외부 환경 정보를 명확히 구분하여 보여줌. 인간이 모델의 추론 흔적(Reasoning traces)을 직접 검토할 수 있어 결정 근거에 대한 진단이 가능하고 사용자 신뢰도를 극대화함.




Figure 1: (1) Comparison of 4 prompting methods, (a) Standard, (b) Chain-of-thought (CoT Reason Only), (c) Act-only, and (d) ReAct (Reason+Act), solving a HotspotQA (Yang et al., 2018) question. (2) Comparison of (a) Act-only and (b) ReAct prompting to solve an AlfWorld (Shridhar et al., 2020b) game. In both domains, we omit in-context examples in the prompt, and only show task solving trajectories generated by the model (Act, Thought) and the environment (Obs).

2. REAC T: SYNERGIZING REASONING + ACTING

- 기존의 환경 상호작용 행동(A)에 언어 공간(L)을 추가하여 $\hat{A} = A \cup L$ 구조를 구축함. 생각(Thought)이라는 언어적 행위는 외부 환경을 변화시키지 않지만, 모델 내부의 문맥을 업데이트하여 복잡한 추론과 계획 수립을 지원함.
- Synergistic Thought Types: 과업 목표 분해 및 계획 수립, 상식 주입, 관측 데이터 요약, 오류 처리 등 인간의 사고 과정을 모사함. 이를 통해 단순 행동만으로는 해결 불가능한 복잡한 문맥 매핑 $c_t \rightarrow a_t$ 문제를 해결함.
- Flexible Interaction Format: 추론 중심 과업(QA 등)에서는 '생각-행동-관측' 단계를 엄격하게 교차시키고, 실행 중심 과업(의사결정 등)에서는 모델이 필요할 때만 생각을 생성하게 하는 비동기적(Asynchronous) 방식을 채택하여 효율성을 극대화함.
- Generalization & Robustness: 별도의 추가 학습 없이 단 1~6개의 퓨샷(Few-shot) 예시만으로도 다양한 도메인에서 SOTA 급 성능을 발휘함. 모델의 행동 공간이나 과업의 성격에 구애받지 않는 강력한 범용 패러다임을 제시함.
- Human Alignment: 모든 의사결정 과정이 자연어로 출력되어 인간이 즉시 검토할 수 있음. 특히 사용자가 모델의 '생각' 텍스트를 직접 편집(Thought editing)함으로써 모델의 행동 방향을 실시간으로 교정할 수 있는 높은 통제력을 제공함.

3. KNOWLEDGE-INTENSIVE REASONING TASKS

3.1) SETUP

- Domain
 - multi-hop 질의응답 벤치마크인 HotPotQA와 사실 검증 데이터셋인 FEVER를 사용.
 - 두 과업 모두 모델에 참고 문단을 미리 주지 않는 질문 전용 설정을 적용하여 모델이 내부 지식에 의존하거나 외부 환경과 상호작용하여 스스로 지식을 찾아내도록 강제함.
- Action space
 - 인간의 정보 탐색 과정을 모사한 단순 위키피디아 API를 설계함.
 - 엔티티 페이지의 첫 5문장을 읽어오는 search, 페이지 내 특정 문자열을 찾는 lookup(Ctrl+F 기능), 최종 답변을 제출하는 finish로 구성됨. 의도적으로 최신 검색 엔진보다 약한 도구를 제공하여 모델이 명시적인 언어적 추론을 통해서만 정보를 타겟팅하도록 유도함.

3.2) METHODS

- HotpotQA와 Fever를 위해 각각 6개와 3개의 퓨샷 예시를 구성함. 질문 분해, 정보 추출, 상식 및 산술 추론, 검색 재구성, 답변 합성 등 다양한 용도의 자유 형식 생각을 행동 및 관측과 결합한 고밀도 사고 궤적을 활용함.
- 베이스라인: ReAct 요소를 단계별로 제거하여 비교군을 형성함. 생각과 행동을 모두 제거한 Standard, 행동을 제외한 추론 중심의 CoT 및 CoT-SC, 그리고 추론 과정을 생략하고 행동만 수행하는 Act 방식을 통해 ReAct의 효용성을 검증함.
- 사실 기반의 ReAct와 구조적 추론에 강한 CoT-SC를 상호 보완적으로 사용함. ReAct가 제한된 단계 내에 실패하거나 CoT-SC의 결과 일관성이 낮아 내부 지식의 신뢰도가 떨어질 때 서로의 방식으로 전환하는 휴리스틱을 적용함.
- 대규모 주석 작업의 어려움을 해결하기 위해 ReAct가 생성한 양질의 정답 데이터 3,000건을 활용함. 이를 통해 PaLM-8B/62B와 같은 소형 모델이 추론 흔적과 행동을 스스로 디코딩할 수 있도록 부트스트래핑 기반의 파인튜닝을 수행함.

3.3) RESULTS AND OBSERVATIONS

Prompt Method ^a	HotpotQA (EM)	Fever (Acc)
Standard	28.7	57.1
CoT (Wei et al., 2022)	29.4	56.3
CoT-SC (Wang et al., 2022a)	33.4	60.4
Act	25.7	58.9
ReAct	27.4	60.9
CoT-SC → ReAct	34.2	64.6
ReAct → CoT-SC	35.1	62.0
Supervised SoTA^b	67.5	89.5

Table 1: PaLM-540B prompting results on HotpotQA and Fever.

^aHotpotQA EM is 27.1, 28.9, 33.8 for Standard, CoT, CoT-SC in Wang et al. (2022b).

^b(Zhu et al., 2021; Lewis et al., 2020)




Figure 2: PaLM-540B prompting results with respect to number of CoT-SC samples used.

	Type	Definition	ReAct	CoT
Success	True positive	Correct reasoning trace and facts	94%	86%
	False positive	Hallucinated reasoning trace or facts	6%	14%
Failure	Reasoning error	Wrong reasoning trace (including failing to recover from repetitive steps)	47%	16%
	Search result error	Search return empty or does not contain useful information	23%	-
	Hallucination	Hallucinated reasoning trace or facts	0%	56%
	Label ambiguity	Right prediction but did not match the label precisely	29%	28%

Table 2: Types of success and failure modes of ReAct and CoT on HotpotQA, as well as their percentages in randomly selected examples studied by human.

- ReAct vs Act & CoT: ReAct는 단순 행동(Act) 방식보다 우수하며, 특히 사실 검증(Fever)에서 CoT를 압도함. CoT의 고질적인 환각 문제(실패 요인의 56%)를 외부 지식 활용을 통해 성공적으로 억제함.
- CoT는 사실 왜곡 오류가 지배적인 반면, ReAct는 구조적 제약으로 인한 유연성 부족이나 부적절한 검색 결과에 의한 추론 오류가 주를 이룸. 이는 두 방식의 장단점이 뚜렷함을 시사함.
- ReAct와 CoT-SC를 결합한 하이브리드 방식이 최고 성능을 기록함. 적은 샘플 수(3~5개)로도 다수의 샘플을 사용한 CoT-SC 단독 성능을 추월하며 내외부 지식 통합의 가치를 증명함.




Figure 3: Scaling results for prompting and finetuning on HotPotQA with ReAct (ours) and baselines.

- 파인튜닝 효과: 소규모 데이터(3,000건) 미세 조정 시 ReAct가 가장 강력한 성능을 발휘함. 8B 모델로 540B 프롬프팅 모델을 능가할 수 있으며, 지식 암기가 아닌 '정보 접근 기술' 학습이 모델의 잠재력을 극대화함.

4. DECISION MAKING TASKS

Method	Pick	Clean	Heat	Cool	Look	Pick 2	All
Act (best of 6)	88	42	74	67	72	41	45
ReAct (avg)	65	39	83	76	55	24	57
ReAct (best of 6)	92	58	96	86	78	41	71
ReAct-IM (avg)	55	59	60	55	23	24	48
ReAct-IM (best of 6)	62	68	87	57	39	33	53
BUTLER _g (best of 8)	33	26	70	76	17	12	22
BUTLER (best of 8)	46	39	74	100	22	24	37

Table 3: AlfWorld task-specific success rates (%). BUTLER and BUTLER_g results are from Table 4 of Shridhar et al. (2020b). All methods use greedy decoding, except that BUTLER uses beam search.

Method	Score	SR
Act	62.3	30.1
ReAct	66.6	40.0
IL	59.9	29.1
IL+RL	62.4	28.7
Human Expert	82.1	59.6

Table 4: Score and success rate (SR) on WebShop. IL/IL+RL taken from Yao et al. (2022).

- 대화형 의사결정 과업 설정: ALFWorld(가상 가사 과업)와 WebShop(실제 웹 쇼핑) 벤치마크를 통해 장기적인 계획 수립과 희소 보상 환경에서의 성능을 평가함. LLM의 사전 학습된 상식과 추론 능력을 활용해 복잡한 환경을 탐색함.
- ALFWorld 성과: ReAct는 71%의 성공률로 행동 전용 방식(Act, 45%)과 방대한 데이터를 학습한 모방 학습 모델(BUTLER, 37%)을 압도함. 사고 과정이 없는 모델이 하위 목표를 놓치거나 상태 추적에 실패하는 지점을 추론으로 보완함.
- WebShop 성과: 118만 개의 실제 상품이 있는 노이즈 많은 환경에서도 이전 최고 기록 대비 성공률을 10% 향상시킴. 복잡한 구매 지침과 실제 상품 옵션 사이의 관계를 논리적으로 연결하여 정확한 의사결정을 수행함.
- 추론의 유연성과 효과: 환경 관측치만 반복하는 기존 방식(IM)보다 고수준 목표 분해와 상식을 결합한 ReAct가 우수함을 입증함. 단순히 외부 피드백에 반응하는 것을 넘어, 능동적으로 계획을 수정하고 다음 단계의 타당성을 검토하는 내부 추론의 중요성을 확인하며 ReAct의 범용적 가치를 보여줌.

5. Related work

- CoT, STaR 등 기존 기법들이 모델 내부의 논리 구조(사고 절차) 강화에 집중했다면, ReAct는 사고 과정에 외부 '행동'과 그에 따른 '관측'을 실시간으로 결합함. 이를 통해 정적인 추론을 동적인 문제 해결 프로세스로 확장함.
- WebGPT나 기존 챗봇(BlenderBot 등)들이 방대한 인간 피드백과 고비용 학습을 통해 API 호출 및 행동을 결정하는 것과 달리, ReAct는 언어적 추론 기술만으로도 훨씬 저렴하고 효율적으로 정책(Policy)을 학습함.

- 로봇 계획 및 폐쇄 루프 시스템: SayCan이나 Inner Monologue(IM)처럼 환경 피드백을 활용하는 기존 연구를 계승하되, 단순히 외부 상태를 나열하는 수준을 넘어 고수준의 목표 분해와 상식 추론을 수행하는 진정한 '내적 언어' 메커니즘을 도입함.
- 언어의 인지적 역할 강조: 언어를 단순한 출력 수단이 아닌, 행동을 제어하고 환경 정보를 처리하는 핵심 인지 도구로 정의함. 이를 통해 일반적이고 다재다능한 에이전트 (Generalist Agent) 구현을 위한 새로운 패러다임을 제시함.

6. Conclusion

- 추론과 행동의 결합을 통해 복잡한 QA 및 의사결정 과업에서 뛰어난 성능과 해석 가능한 의사결정 경로를 동시에 확보함. 단순한 구조임에도 다양한 도메인에서 모델의 실용성을 증명함.
- 행동 공간이 넓은 복잡한 과업의 경우 많은 예시 데이터가 필요하며, 이는 프롬프트의 입력 길이 제한(Context Length) 문제로 이어짐. 초기 미세 조정 실험으로 가능성을 보였으나, 여전히 양질의 인간 데이터가 추가로 필요한 상황임.
- 다중 작업(Multi-task) 학습을 통한 규모 확장과 강화 학습(RL)과의 결합을 핵심 과제로 제시함. 이를 통해 언어 모델이 단순한 텍스트 생성을 넘어 실질적인 문제 해결 능력을 갖춘 강력한 에이전트로 진화할 잠재력을 강조함.