

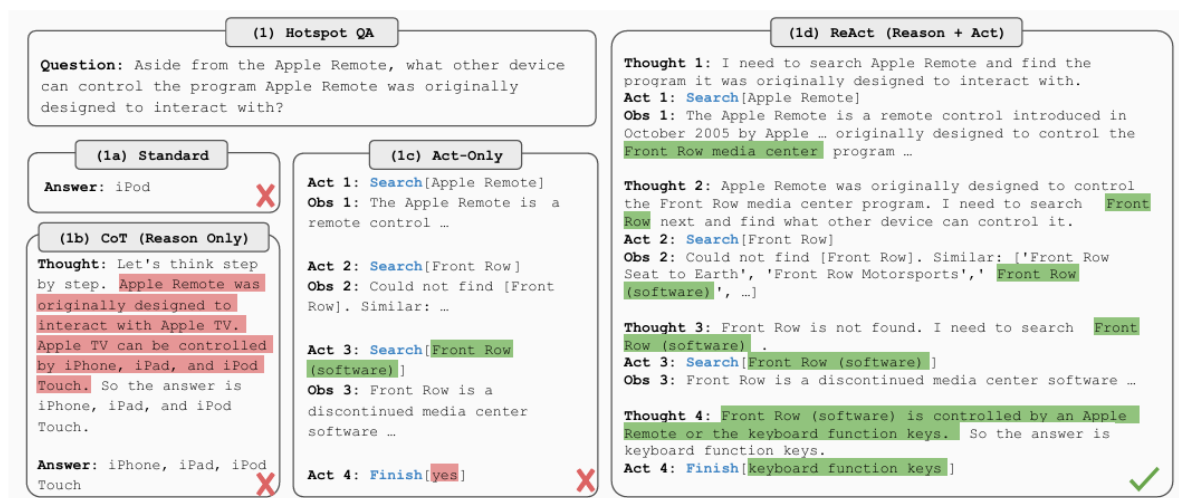
REACT: Synergizing Reasoning and Acting in Language Models

1. Introduction

대형 언어 모델은 최근 언어 이해와 의사결정 과제에서 높은 성능을 보였지만, **reasoning**과 **acting** 능력은 주로 서로 분리된 형태로 연구됨.

Chain-of-Thought(CoT)는 언어 기반 추론을 생성할 수 있지만 외부 세계와 상호작용하지 못하고, 반대로 action generation 기반 접근은 환경과 상호작용할 수 있으나 고수준 목표에 대한 추론 능력이 제한적임

따라서, CoT는 외부 지식에 근거하지 못해 hallucination이나 오류 전파가 발생할 수 있으며, action-only 접근은 계획 수립이나 상태 추적과 같은 고수준 reasoning이 부족



본 논문은 **ReAct**라는 프롬프트 기반 패러다임을 제안하여, 언어 모델이 추론과 행동을 번갈아 생성하도록 함

이를 통해 reasoning은 행동 계획을 생성·수정하는 데 사용되고, 행동은 외부 환경에서 정보를 획득하여 reasoning을 보강하는 상호 보완적 구조를 형성

2. Method

ReAct는 환경과 상호작용하는 에이전트 설정을 따름. 시간 t 에서 에이전트는 관측을 받고 행동을 선택

$$c_t = (o_1, a_1, \dots, o_t)$$

기존 방식은 행동 공간 A 만 사용하지만, ReAct는 이를 확장하여

$$\hat{A} = A \cup L$$

로 정의한다. 여기서 L 은 **언어 기반 reasoning(Thought) 공간**

- a_t : 환경에 영향을 주는 실제 행동
- a^t : 환경을 바꾸지 않는 내부 reasoning

Thought는 관측에 대한 해석, 목표 분해, 계획 수정 등의 역할을 수행하며 이후 행동 선택을 도움

ReAct trajectory는 다음과 같은 반복 구조를 가짐

Thought $\rightarrow$ Action $\rightarrow$ Observation $\rightarrow$ Thought $\rightarrow$...

이 구조는

- Reason to Act (추론으로 행동 계획)
- Act to Reason (행동으로 정보 획득)

의 상호작용을 가능하게 함

3. Experiments

3.1 Knowledge-Intensive Reasoning Tasks

다중 홉 QA(HotpotQA)와 사실 검증(FEVER)에서 Wikipedia API와 상호작용하도록 설계 Action space는 다음 세 가지로 구성

- search[entity]
- lookup[string]
- finish[answer]

Prompt Method ^a	HotpotQA (EM)	Fever (Acc)
Standard	28.7	57.1
CoT ^{Wei et al., 2022}	29.4	56.3
CoT-SC ^{Wang et al., 2022a}	33.4	60.4
Act	25.7	58.9
ReAct	27.4	60.9
CoT-SC → ReAct	34.2	64.6
ReAct → CoT-SC	35.1	62.0
Supervised SoTA^b	67.5	89.5

Table 1: PaLM-540B prompting results on HotpotQA and Fever.

^a HotpotQA EM is 27.1, 28.9, 33.8 for Standard, CoT, CoT-SC in Wang et al. (2022b).

^b Zhu et al. 2021, Lewis et al. 2020




Figure 2: PaLM-540B prompting results with respect to number of CoT-SC samples used.

결과적으로 ReAct는 action-only 모델보다 일관되게 높은 성능을 보였으며, 외부 지식을 활용함으로써 CoT에서 나타나는 hallucination을 줄임. 또한 ReAct와 CoT-Self-Consistency를 결합한 방식이 가장 높은 성능을 보였으며, 이는 내부 지식과 외부 지식의 결합이 중요함을 의미함

3.2 Interactive Decision-Making Tasks

텍스트 기반 게임(ALFWorld)과 웹 환경(WebShop)에서 장기 의사결정 능력을 평가

- ALFWorld: 가정 환경에서 목표 달성
- WebShop: 온라인 쇼핑 환경에서 조건에 맞는 상품 선택 react

Method	Pick	Clean	Heat	Cool	Look	Pick 2	All
Act (best of 6)	88	42	74	67	72	41	45
ReAct (avg)	65	39	83	76	55	24	57
ReAct (best of 6)	92	58	96	86	78	41	71
ReAct-IM (avg)	55	59	60	55	23	24	48
ReAct-IM (best of 6)	62	68	87	57	39	33	53
BUTLER _g (best of 8)	33	26	70	76	17	12	22
BUTLER (best of 8)	46	39	74	100	22	24	37

Table 3: AlfWorld task-specific success rates (%). BUTLER and BUTLER_g results are from Table 4 of Shridhar et al. (2020b). All methods use greedy decoding, except that BUTLER uses beam search.

Method	Score	SR
Act	62.3	30.1
ReAct	66.6	40.0
IL	59.9	29.1
IL+RL	62.4	28.7
Human Expert	82.1	59.6

Table 4: Score and success rate (SR) on Webshop. IL/IL+RL taken from Yao et al. (2022).

ReAct는 imitation learning 및 reinforcement learning 기반 방법보다 높은 성공률을 보임.

Action-only 방식은 현재 상태를 잃거나 잘못된 하위 목표를 설정하는 문제가 자주 발생

4. Conclusion

본 논문은 ReAct라는 간단한 프롬프트 기반 패러다임을 통해 언어 모델이 **추론과 행동을 통합**하여 다양한 reasoning 및 의사결정 과제에서 성능을 향상시킬 수 있음을 보임

⇒ 특히 **외부 환경과 상호작용을 통해 사실 기반 추론을 수행하고, 해석 가능한 의사결정 과정을 제공**한다는 점에서 기존 reasoning-only 또는 action-only 접근 대비 장점을 가짐. 향후 더 많은 데이터로의 파인튜닝이나 강화학습과의 결합이 성능 향상에 중요한 방향으로 제시됨