

Neural Operator 기반 초해상도 재구성

CV 2팀 | 22기 장건희, 22기 황원준, 23기 김병현

CONTENTS

01

Introduction

LIIF
Neural Operator
Fourier Neural Operator
Super Resolution Neural Operator

02

Methodology

SRNO Based Experiments
LNO Based Experiments

03

Experiment

Setup
Numerical Analysis
Visualization
Interpretation

04

Conclusion

Summary
Limitations





01. Introduction

01. 초해상도

- 초해상도 (Super-resolution)
 - 저해상도 이미지에서 고해상도 이미지로 복원하는 기술
 - 하나의 저해상도 이미지는 여러 고해상도 이미지로부터 생성 가능
 - 즉, 역과정을 푸는 문제이고 다대일 매핑에서 선택하는 문제
→ 난이도가 높다





Figure 6: Demonstration of the generated LIIF representation, presented in $\times 20$ higher resolution than the input.

01. LIIF

- LIIF(Local Implicit Image Function)

- 이미지를 끊어진 픽셀의 집합이 아닌 연속적인 함수로 정의
- 좌표(x, y)를 입력하면 해당 위치의 RGB 값을 반환 ($RGB = f(x, y)$)
- 현재 초해상도 분야의 baseline



- LIIF의 장점

- 학습된 배율뿐만 아니라 학습하지 않은 배율(x6, x30 등)로도 자유롭게 확대 가능
- 벡터 이미지처럼 깨짐 없는 연속적인 표현 가능

$$S_{ensemble} = \sum_{j \in \{1,2,3,4\}} \frac{w_j}{W} f_{\theta}(z_j, x - c_j)$$

01. LIIF

○ LIIF의 단점

- 픽셀 하나하나마다 MLP 수행(Point-wise MLP)하여,
주변 픽셀과의 관계나 전체적인 패턴 고려하지 않음
 - Global Context 부재: 이미지 전체의 구조적 정보나 반복되는 패턴의 부재
 - High-Frequency 손실: 복잡한 무늬나 경계선에서 디테일이 뭉개지는 현상
- 이미지 전체를 한 번에 볼 수 있는 대안의 필요성

01. Neural Operator

- Neural Operator의 배경
 - 과학/공학에서 문제들은 주로 편미분방정식으로 기술됨
 - 편미분방정식의 해는 함수이므로, 신경망이 함수를 출력하게 해야 함
 - 기존 Neural Networks: 고정된 입력 값 $\rightarrow$ 고정된 출력 값 (벡터 매핑)
 - 연산자(함수에서 함수로의 매핑)를 학습시켜보자는 아이디어 등장


01. Neural Operator

- Neural Operator?
 - 기존 Neural Networks: 고정된 입력 값 $\rightarrow$ 고정된 출력 값 (벡터 매핑)
 - Neural Operator: 입력 함수 $\rightarrow$ 출력 함수 (Operator/함수 매핑)
- Neural Operator 장점
 - 함수 사이의 관계를 학습하기 때문에 학습 해상도에 얽매이지 않고 임의의 해상도에서 함수 값 추론 가능 - Discretization Invariance
 - 이미 과학/공학 문제들에서 초해상도 Task 수행 능력이 여러 차례 증명됨
 - 적분 연산을 통해 이미지 Global Context를 한 번에 처리

01. Neural Operator

- 일반적으로, 미분방정식 $(\mathcal{L}_a u)(x) = f(x)$ 의 해 $u(x) = \int_D G_a(x, y) f(y) dy$ 와 같이 적분 꼴로 표현 가능 $\rightarrow G_a(x, y)$ 를 모사하는 $\kappa(x, y)$ 를 학습 시도
- 구조 (Lifting $\rightarrow$ Iterative Layers $\rightarrow$ Projection)
 - Lifting: $v_0(x) = P(x, a(x)) + p$
 - Iterative Layers: $v_{t+1}(x) = \sigma(W v_t(x) + \int_B(x, r) \boxtimes [\kappa_\phi(x, y, a(x), a(y)) v_t(y) dy])$
 - Projection: $u(x) = Q v_T(x) + q$

(a)



01. Fourier Neural Operator

○ 기존 접근 방법의 문제점

- 적분 연산의 계산량이 너무 큼: $O(N^2)$
- 두 점의 절대적 위치 $x, y(\kappa(x, y))$ 가 아닌 상대적 위치 $x-y(\kappa(x - y))$ 에만 커널 함수가 의존하게 한다면?
 - $u(x) = \int_D \kappa(x - y)v(y)dy = (\kappa * v)(x)$ 합성곱의 형태가 됨
 - $u(x) = \mathcal{F}^{-1} \left(\mathcal{F}(\kappa_\phi) \cdot \mathcal{F}(v) \right) (x)$ 합성곱은 주파수 공간에서 element-wise 곱(합성곱 정리)
 - 즉, 푸리에 역변환과 푸리에 변환이 계산 부담의 대부분 ($O(N^2) \rightarrow O(N \log N)$)

* 합성곱 정리: $\mathcal{F}(\kappa * v) = \mathcal{F}(\kappa) \cdot \mathcal{F}(v)$


01. Fourier Neural Operator

○ 푸리에 변환의 장점

- 합성곱 정리: $\mathcal{F}(\kappa * v) = \mathcal{F}(\kappa) \cdot \mathcal{F}(v)$
 - 기존 도메인에서 계산 비용이 매우 큰 적분 연산이 주파수 공간에서 element-wise 곱으로 변환
 - FNO의 효율성에 가장 크게 기여한 성질
- 미분 연산을 상수곱으로 대체: $\mathcal{F}\left\{\frac{df}{dt}\right\} = i\omega\mathcal{F}\{f\}$
 - 미분 연산이 주파수 공간에서 단순히 상수를 곱하는 연산이 됨
 - 복잡한 계산 없이 그래디언트 전달 가능

01. Fourier Neural Operator

$$v_{t+1}(x) := \sigma \left(W v_t(x) + \mathcal{F}^{-1} \left(\mathcal{F}(\kappa_\phi) \cdot \mathcal{F}(v_t) \right) (x) \right)$$




(a) The full architecture of neural operator: start from input a . 1. Lift to a higher dimension channel space by a neural network P . 2. Apply four layers of integral operators and activation functions. 3. Project back to the target dimension by a neural network Q . Output u . **(b) Fourier layers:** Start from input v . On top: apply the Fourier transform $\mathcal{F}$; a linear transform R on the lower Fourier modes and filters out the higher modes; then apply the inverse Fourier transform $\mathcal{F}^{-1}$. On the bottom: apply a local linear transform W .

Figure 2: **top:** The architecture of the neural operators; **bottom:** Fourier layer.

01. Fourier Neural Operator

- Fourier Neural Operator의 문제점 - 푸리에 변환에 의존적
 - 주기적이지 않은 신호를 표현하기 위해서는 임의의 많은 주파수를 고려해야 됨
 - 푸리에 변환이 불가능한 경우 적용 불가능
 - 신호가 작아지거나 증폭하는 경우




01. Super Resolution Neural Operator

- Operator 개념을 도입한 Continuous Super-resolution
 - LIIF의 한계점(Global Context 부재, High-Frequency 손실) 해결하기 위해,
이미지를 개별 점이 아닌 '함수'로 재정의
 - 이미지 전체를 LR(저해상도 함수) $\rightarrow$ HR(고해상도 함수)로 매핑 및 변환하는 Operator 도입
- Global context 파악 가능
- 입·출력 격자 크기에 의존하지 않는 연속적인 해상도 복원


01. Super Resolution Neural Operator

○ Lifting – Integral – Projection 구조



출처: <https://arxiv.org/abs/2303.02584>

- Lifting to Latent Space
 - LR 이미지 → CNN → LR feature: global 연산 이전 local feature 혼합하여 공간 정보 강화
 - HR 좌표에서 LR feature를 bilinear 샘플링하여 보간 후 (feature, 좌표) → 초기 latent z_0
- Kernel Integral (T steps)
 - global 연산으로 latent 반복 업데이트
- Projection
 - Latent z_T → RGB residual, bilinear upsample을 더해 HR 이미지 복원



01. Super Resolution Neural Operator


○ Kernel Integral as Neural Operator

- 일반 self-attention: $\text{Softmax}(QK^T)V \rightarrow O(n^2 \cdot d)$


- token 간 pairwise 유사도 기반 확률적 가중합
- SR에서는 고해상도일수록 n 이 커져 계산량 부담

- Galerkin-type attention: $z = Q(K^TV) \rightarrow O(n \cdot d^2)$

- K^TV 로 global basis 생성 후 Q 로 모든 좌표 projection → 모든 좌표가 공유하는 global operator로 latent $z(x)$ T번 업데이트



- 확률적 유사도 학습이 아닌 적분 연산(Integral Operator) 관점의 전역 연산 구조



01. Laplace Neural Operator

- 라플라스 변환으로 푸리에 변환을 대체
 - FNO의 문제점(비주기적 신호, 증폭하는 시스템 표현 등) 해결 목적

$$u(t) = \mathcal{Q} \circ \sigma \left(\mathcal{L}^{-1} \left(\mathcal{L}(\kappa_\phi) \cdot \mathcal{L}(v) \right) (t) + Wv(t) \right) \circ \mathcal{P}$$

- 라플라스 변환: $\mathcal{L}\{x(t)\} = \int_0^\infty x(t)e^{-st}dt$ ($s = \sigma + i\omega$)
 - $e^{-\sigma t}$ 가 포함되어서 커지거나 작아지는 시스템 처리 가능
 - 주기적이지 않은 신호, 시스템에 대한 처리 가능
 - 푸리에 변환과 마찬가지로 합성곱 정리가 성립

01. Laplace Neural Operator

$$u(t) = Q \circ \sigma(\mathcal{L}^{-1}\{K(s) \cdot V(s)\} + Wv(t)) \circ \mathcal{P}$$




Fig. 1 | Illustration of the new architecture of LNO. **a**, A schematic representation of the entire architecture of the LNO. We start with an input function $f(t)$ and carry out the following steps: (1) Lift the input function to a higher dimension by a shallow neural network $\mathcal{P}$. (2) Apply a Laplace layer and a local linear transform W . (3) Project the output, $u(t)$, back to the target dimension employing a shallow neural network, Q . **b**, Laplace layer: start from input $V(s)$.

Top row: apply the pole-residue method to compute the transient response residues γ_n based on the system poles μ_n and residues β_n ; express the transient response u_{tr} in the Laplace domain. Bottom row: apply the pole-residue method to compute the steady-state response residues λ_l based on the input poles $i\omega_l$ and residues α_l ; express the steady-state response u_{st} in the Laplace domain.

01. Laplace Neural Operator

- 입력 신호 분해(라플라스 분해, $O(N \log N)$) → 지수 함수의 합으로 표현 가능
 - 아래와 식과 같이 커널 적분 결과 계산 가능
 - 즉, 단 한번의 라플라스 변환과 지수 함수의 가중치합으로 커널 적분을 대체 가능

$$u(t) = \underbrace{\sum_{n=1}^N \gamma_n e^{\mu_n t}}_{\text{비주기적 신호}} + \underbrace{\sum_{l=-L}^L \lambda_l e^{i\omega_l t}}_{\text{주기적 신호}}$$

- FNO에 비해 시간/공간적으로 효율적임이 실험적으로 증명되어 있음

01. Neural Operator

○ LIIF vs. Neural Operator 비교

비교 항목	LIIF (Local Implicit Image Function)	Neural Operator (e.g., FNO, SRNO)
수학적 정의	$f_{\theta}(z, x - x^*) \rightarrow \text{RGB}$	$G: \mathcal{A} \rightarrow \mathcal{U}$
접근 방식	좌표 기반 추론	함수 공간 매핑
주요 연산	Local Feature Query + Point-wise MLP	Global Integral Kernel / Spectral Conv
시야	해당 좌표 주변의 좁은 영역만 참조	이미지 전체의 정보를 참조
해상도 제어	쿼리하는 좌표의 밀도에 따라 결정	입·출력 샘플링 해상도에 무관(Invariant)
강점	복잡한 이미지의 날카로운 경계선 및 디테일	전역적 패턴 복원 우수, 고배율에서도 물리적 일관성 유지
적합 태스크	단일 객체 복원, 픽셀 단위 예측	PDE 풀이, 과학 시뮬레이션, 복잡한 초해상도
학습 복잡도	상대적으로 가벼우나 추론 시 점마다 MLP를 돌려야 함	초기 학습 및 설계 비용은 있으나 한 번 학습하면 추론이 매우 빠름



02. Methodology

02. SRNO - experiments

1. Baseline

→ operator 구조 자체 검증

2. Fourier PE

→ Spectral bias 완화 가능성 확인

3. L 값 비교

→ 표현력 vs 안정성 trade-off 분석

4. Local ensemble encoding

→ local 결합 방식 변화가 성능에 미치는 영향


Model	Global Context	High Freq	Local Bias
Baseline	✓	△	△
+ Fourier(L=5)	✓	✓	△
+ Fourier(L=10)	✓	✓✓	△
+ Local Aggregation	✓	△	✓

02. SRNO - baseline

- 논문 구조(L-K-P) 재현하되 일부 단순화
 - 논문의 성능 재현보다 Continuous operator 구조의 특성 탐구에 초점을 둠
 - Encoder: EDSR / RDN → EDSR only
 - latent 차원 $d_z = 256$, Integral Steps $T = 2$ 고정(논문 기본 설정을 따름)
 - 기타 Setup은 03.Experiment 후술
- 목적
 - 모델 용량을 고정하고 operator 구조 효과만 검증
 - 이후 Fourier encoding 및 local aggregation 실험의 기준점 역할

02. SRNO - Fourier PE

- 문제 상황: Spectral bias
 - 신경망은 저주파를 먼저 학습 → 경계선, 텍스처 등 고주파 복원 어려움
- 실험: Fourier Coordinate Encoding
 - 좌표를 고주파 Fourier basis로 확장하여 Lifting 입력 feature에 concat
 - $\gamma(x) = [x, \sin(2^l \pi x), \cos(2^l \pi x)]$
- 주파수 확장 효과(최대 2^{L-1}) 영향 분석
 - $L=5 \rightarrow$ 최대 16배, $L=10 \rightarrow$ 최대 512배 증가
 - 표현력 증가 $\leftrightarrow$ 과적합 위험 증가 trade-off



$$a(x) \rightarrow a'(x) = [a(x), \gamma(x)]$$
$$z_0(x) = \mathcal{L}(\text{Interpolation}(E_\psi(a'(x))))$$


02. SRNO - Local Aggregation

○ 기존 SRNO의 가정

- 전역 Kernel Integral이 충분한 global context를 학습
- local ensemble 미사용 → 4개 코너 feature를 단순 concat
- 코너 중요도는 네트워크가 학습에 의존

○ 검증: LIIF-style Local Ensemble 적용

- HR 좌표를 LR 셀 내부 상대 위치 반영
 - 4개 코너 feature 중 가까운 코너에 더 큰 weight 부여 → 위치 기반 inductive bias 추가
- Local 결합 방식이 성능에 미치는 영향 검증



Baseline:

$$a(x) = \text{Concat}(f_1, f_2, f_3, f_4)$$

↓

Local Ensemble:

$$a(x) = \sum_i w_i f_i, \quad w_i \propto \frac{1}{|\Delta x_i \Delta y_i| + \epsilon}$$

02. LNO - Upgraded


- LNO 기반 + Channel Mixer: LNO-CoDA
 - 채널 간 관계를 놓치지 않도록 정보를 혼합
 - 저해상도 이미지의 Bicubic에 잔차를 더하는 방식으로 모델은 고주파 디테일 복원에만 집중하도록 유도
- Loss: Pixel Loss + Spectral Loss
 - Pixel Loss: 필터로 엣지 맵 추출해서 모델이 엣지 부분에 더 집중하도록 가중치 부여
 - Spectral Loss: FFT 공간에서 정답과 예측의 주파수 성분의 L1 loss



03. Experiment

03. Setup

- 데이터셋: DIV2K
 - DIV2K_train_HR(800장), DIV2K_valid_HR(100장)
 - 다양한 장면과 고해상도 이미지를 통해 모델 성능 향상 가능



03. Setup

• Training Settings(공통)

HR Patch	192 × 192
Train Scale	{2, 3, 4}
LR Size	192 / scale → 96, 64, 48
Validation	×2

• Training Settings(SRNO)

Width	128
Attention Blocks	8
Supervision	4096 sampled coords
Loss	L1
Optimizer	Adam (4e-5)
Warmup	20
Grad Clip	1.0
Batch	4
Epoch	400

03. Setup

- Training Settings(공통)

HR Patch	192 × 192
Train Scale	{2, 3, 4}
LR Size	192 / scale → 96, 64, 48
Validation	×2

- Training Settings(LNO)

Width	64
Layers	4
Supervision	Full grid (192×192)
Loss	L1 + Spectral
Optimizer	AdamW (1e-5)
Scheduler	Warmup 10 + Cosine
Batch	32
Epoch	2000

03. PSNR

○ 비교 설정

- Dataset: DIV2K Validation (100 images)
- Patch Sampling: 각 이미지에서 HR patch (192×192) 랜덤 크롭
- LR Generation: HR patch를 bicubic downsampling하여 LR 생성
 - scale $\times 2$ / $\times 3$ / $\times 4$, random scale

→ 100장의 복원 PSNR (dB) 평균으로 비교



03. PSNR

○ PSNR (dB) 평균 비교

Model	x2.0	x3.0	x4.0	Random
Bicubic	36.17	32.50	31.17	33.79
SRNO-Base	37.46	33.05	31.50	34.30
SRNO-Fourier(L=5)	37.42	33.05	31.46	34.28
SRNO-Fourier(L=10)	37.46	33.08	31.51	34.32
SRNO-LocalAgg.	37.01	32.81	31.22	33.98
LNO-Base	35.70	31.47	30.14	32.78
LNO-CoDA	35.77	31.55	30.17	32.83
LNO-CoDA-BIG	36.17	31.92	30.89	33.22

03. Visualization

- SRNO x2



GT



Bicubic 보간
PSNR 27.48



Baseline
PSNR 32.16



Fourier5
PSNR 31.95



Fourier10
PSNR 32.24



LocalAgg
PSNR 31.30

03. Visualization

- SRNO x3



GT



Bicubic 보간
PSNR 22.80



Baseline
PSNR 25.39



Fourier5
PSNR 25.30



Fourier10
PSNR 25.60



LocalAgg
PSNR 25.08

03. Visualization

- SRNO x4



GT



Bicubic 보간
PSNR 21.48



Baseline
PSNR 22.98



Fourier5
PSNR 22.90



Fourier10
PSNR 23.08



LocalAgg
PSNR 22.77

03. Visualization



GT



Fourier10
PSNR 23.08



Baseline
PSNR 22.98

03. Visualization

- LNO based: loss를 최소화하기 위해서 입력을 그대로 출력하게 되어버린다.
- 극단적인 점별 연산과, 전역 연산 때문에 작은 주변 영역의 정보는 무시하게 됨.

0891.png | Scale x2 | Crop(187, 801)

Bicubic
28.80 dB



lno_base
28.80 dB



codalno
28.80 dB



upgrade
28.80 dB



Ground Truth (HR)



0878.png | Scale x2 | Crop(504, 504)

Bicubic
36.85 dB



lno_base
36.85 dB



codalno
36.85 dB



upgrade
36.85 dB



Ground Truth (HR)



03. Interpretation

○ Fourier 주파수 실험

- 전체 평균 PSNR 변화폭 미미하나, 시각적으로 특정 고주파 영역에서 부분적 개선 확인

→ 고주파 함수 근사에 도움

- 이미지 및 배율에 따라 우세한 모델이 달라짐

- Scale이 커질수록 fourier100이 상대적으로 우세
- 에지/텍스처가 많은 고주파-rich 패치: L=10 우세
- 부드러운 영역 지배적인 smooth 패치: L= 5 우세

→ 패치 특성에 따라 주파수 L을 동적으로 선택하는 Gating 구조 실험 가능성

03. Interpretation

- Local Aggregation 실험
 - 모든 scale에서 Baseline 대비 PSNR 감소, 시각적 비교에서도 선명도 및 디테일 감소
 - 고정 가중치 결합이 표현력 제한
 - SR은 상황별 가중치 변화가 중요하나, 4-corner 정보를 사전 압축하여 모델 추론 기회 박탈
 - 동적 basis update/전역 조합에 불리
 - 복원 Scale 커질수록 좌표 간 거리 증가로 고정 가중치 방식의 경계 복원 한계 심화
 - SR 문제에서는 유연한 feature 조합이 중요



04. Conclusion

04. Summary

- Continuous SR 구조 탐구
 - 기존 CNN 기반 고정 해상도 방식의 한계를 극복하기 위해 Neural Operator 기반 SOTA 모델의 임의 배율 복원 성능 분석
- 실험적 성능 분석 및 구현
 - SRNO 및 LNO 모델 구현 및 학습 재구성 통해 성능 개선 시도
 - SRNO / SRNO+Fourier PE / SRNO+Local ensemble로 좌표 표현력 강화 시도
 - Fourier PE 적용 시, arbitrary-scale SR 및 디테일 복원 성능 향상 기대
 - LNO / LNO+CoDA
 - Laplace Transform, Channel Attention 결합을 통한 비선형 특징 추출 능력의 극대화 시도

04. Limitations

- Neural Operator 기반 접근의 한계
 - 좌표 샘플링의 Continuous 구조로 인한 학습 과정의 High Variance 발생
 - PDE와 이미지의 차이: 연속적 vs 불연속적, 전역 상호작용 vs 국소 상호작용, 목표: 함수 공간 vs pixel
 - 하이퍼 파라미터에 따라 학습 변동이 커 모델의 안정적인 재현 및 확장이 까다로움
- 아키텍처 탐구의 범위적 한계
 - 특정 모델에 종속된 구조적 실험으로 다양한 Neural Operator 아키텍처에 대한 범용적 검증 부족
- 학습 리소스 및 평가의 제한성
 - DIV2K 단일 데이터셋 기반 실험으로 인해 다양한 도메인에 대한 일반화 성능 검증 부족
 - PSNR 중심의 정량적 평가에 집중하여, 실제 시각적 인지 품질에 대한 종합적 판단의 한계 존재



Thank You