

전국단위 홍수 발생 후 수인성 감염병 발생 예측 모델

ML1팀 |
23기 신지유, 23기 이서현,
23기 윤지원, 23기 홍준기

KUBIG
DATA SCIENCE & AI

CONTENTS

01

주제 소개

- 주제 선정 배경
- 주제 및 문제 정의

02

전처리 및 EDA

- 데이터 셋 구성
- 변수 설명
- EDA
- 전처리

03

모델링

- 시차 상관
- Random Forest
- Light GBM

04

결과 및 추후 과제

- 기후변화시나리오





01. 주제 소개

01.1 주제 선정 배경



2025 환경데이터 활용 및 분석 공모전
2025.4.7.(월) - 5.19.(월)

산 | 청 | 에코톤 홈페이지 접수 (<https://www.ecothon.kr/>)

공모부문 | 공모일정 |

공모부문	공모자격
사업 아이디어 기획	대중인
제품-서비스-앱 개발	기업 또는 창업(예정)자
분석	데이터 직접분석 대학(원)생

공모일정 |

공모 접수 > 사업안서 및 발표신청 > 발표심사 > 최종결과 발표

대상지역 |

구분	수량	상금(천원)	사업 아이디어 기획	제품-서비스-앱 개발	분석	총액
대 상	3명	1,500	1명 400만원	1명 600만원	1명 500만원	환경부장관상
최우수상	3명	900	1명 250만원	1명 350만원	1명 300만원	주관·공동 주관기관
우수상	5명	1,050	2명 150만원/명	1명 250만원	2명 250만원/명	
장려상	7명	550	3명 50만원/명	2명 100만원/명	2명 100만원/명	

문의처 | T. 043)254-7942

주최 | 환경부 주관 | 한국환경공단 KEITI 한국환경산업기술원

참여기관 | K water 국립환경연구원 국립생태원 국립환경과학원 KHS 한국수자원공사 KECI 한국환경정보원

환경데이터 분석 부문



아래 4개 미션 수행을 위한
데이터 분석 수행과제

- ▶ 대학(원)생
- * 접수 마감일 기준 재학증명서의 발급이 가능한 대학(원)생

#건강한 생활환경 #기후위기에 강한 물 환경과 자연생태계 조성
#미세먼지 걱정없는 푸른 하늘 #재활용을 통한 순환경제 완성

접수하기

[2026 환경데이터 활용 및 분석 공모전]

#환경 #시계열 #데이터모델링 #공공데이터

대회 목표 : 환경분야 공공데이터를 활용하여

환경 문제를 데이터 기반으로 분석, 해결

수행과제 : 건강한 생활 환경 -> **환경보건 서비스**

01.2 주제 및 문제 정의

[전국 단위 홍수 발생 후 수인성 감염병 발생 예측 모델]

- 기후변화로 홍수, 폭우, 침수 등 이상기후 빈도 증가
- 이로 인한 국내 수인성 감염병 증가 예측, 초기 대응

* 핵심 연구 질문

기후 재난 발생 후, 수인성감염병이 얼마나 늦게,
얼마나 많이 증가하는가?

-> 다음주 감염병 발생 위험을 예측할 수 있는가?

"폭우, 관측기록 다 깨버려...기후위기에 따른 복합재난, 과할 정도로 대비해야"

[스팟인터뷰] 윤진호 GIST 환경에너지공학과 교수 "기상청 예보 정교화, 재난 대비 투자에 나서야"

전국적 폭우에 수인성 감염병 확산 주의보

침수·하수 범람으로 병원균 확산 위험 ↑ ... "개인위생 철저히"



김다정 기자 발행 2025.07.18 18:53

바이오 / 복지 · 의료

"비 그친 뒤 더 무서운 게 온다"...수인성 감염병, 이렇게 많아?



장도민 기자

업데이트 2025.07.20 오전 11:40 ✓

* 수인성 감염병 : 병원성 미생물(세균, 바이러스, 원충)이
오염된 물에 의해 전파되는 질병

주요 경로 : 홍수, 폭우 등으로 하수 역류 -> 분변 오염 -> 식수, 식품 오염



02. 데이터 개요 및 전처리

02.1 데이터셋 구성

A	B	C	D	E	F	G	H	I	J	K	L	M
	year	week	rain_nat	erer	rain_diff	water_temp	DO	BOD	COD	pH	coli_log_mean	coli_mean
0	2015	1	3.772672436		0 3.772672436	1.701245905	15.62204648	1.936856061	3.76489353	6.748502252	7.834626939	3550.33791
1	2015	2	1.185418595		0 -2.58725384	3.712222652	13.4663999	2.436845556	4.732934412	7.682215919	8.715310997	12603.78245
2	2015	3	2.691617321		0 1.506198726	3.724155194	14.03590216	2.379334316	4.717392846	7.709611345	8.623321437	21492.60898

N	O	P	Q	R	S	T	U	V	W	X
cases_bacteria	cases_virus	cases_protozoa	temp	humidity	pop_area	sum_weighted_a	sum_flood_area	avg_flood_intens	pop_weighted_intensity	
6	89	2	-0.2628358091	3.199136661	0	0	0	0	0	
12	78	1	-0.01385419505	3.658332016	0	0	0	0	0	
13	117	5	0.03708507809	3.580605406	0	0	0	0	0	

- 2015 ~ 2022년 주차별 시계열 데이터
- 세균, 바이러스, 원충성 수인성 감염병 발생 특성이 달라, 구분하여 분석

02.2 변수 설명




y 변수 : 주차에 따른 세균, 바이러스, 원충성 감염병 발생 수 (2015~2022)

X 변수 :

- 강수, 기후 노출 변수 : 인구 가중 평균 강수량, 극한 강수 노출 인구 비율,
전주 대비 강수량 증감률
- 침수, 홍수 노출 변수 : 전국 침수 면적 합계, 침수 인구 노출 비율
- 병원체 생존 환경 변수 : 전국 인구 가중 평균 기온, 습도, 수질 지표(수온, DO, BOD, pH, 대장균 수 등)
- 계절성 통제 변수 : 월 더미 변수


02.3 EDA

- 데이터 분포 확인



02.3 EDA

- 데이터 분포 확인



02.4 전처리

- 시차 변수 생성











: 잠복기와 환경 전파 시간을 고려하여 1주에서 4주 전의 시차(Lag 1~4)를 둔 독립 변수 생성

- 월별 변수 생성

: 뚜렷한 계절성 확인 (virus, bacteria)

- 표준화

: standard scaler 활용 연속형 변수 표준화



* 세균성 장관감염증 발생 건수 ACF, PACF, Lag correlation



03. 모델링

03.1 수인성감염병 모델링 - 세균성

지연 상관 (Lag Correlation) 확인



* 상관계수 기준 결정

- 강수량 변수 : Lag 3, 침수 변수 : Lag 2, 기온 : Lag 2
- 수질 지표 : 성능 저하 및 지연효과 불규칙 -> 사용 X
- 감염병 발생 수(cases_bacteria) : Lag 1, 2, 3

전처리

- cases_bacteria skewed -> log 변환
- test/train set split :

2022년 test set, 2015~2021년 train set



03.1 수인성감염병 모델링 - 세균성

Baseline model

1) Random Forest



- 시계열 데이터 -> TimeSeriesSplit 활용 hyper parameter 튜닝

CV best RMSE : 0.296

`n_estimators = 1200, max_depth = 20, min_samples_split=10, min_sample_leaf :2, max_features : 0.7`

Test RMSE : 0.159

극한값 (cases_bacteria 상위10%) 발생 예측 확률 : 0.714



03.1 수인성감염병 모델링 - 세균성

Baseline model

2) XGBoost


- 시계열 데이터 -> TimeSeriesSplit 활용 hyper parameter 튜닝

CV best RMSE : 0.304

max_depth : 2, learning_rate : 0.1, n_estimators : 300, reg_lambda : 1.0, reg_alpha = 0.1

Test RMSE : 0.211

극한값 (cases_bacteria 상위10%) 발생 예측 확률 : 0.857



03.1 수인성감염병 모델링 - 세균성

Baseline model


3) LightGBM

- 시계열 데이터 -> TimeSeriesSplit 활용 hyper parameter 튜닝

CV best RMSE : 0.303

Test RMSE : 0.182

극한값 (cases_bacteria 상위10%) 발생 예측 확률 : 0.786



03.1 수인성감염병 모델링 - 세균성

Baseline model

잔차기반 Random Forest - $\hat{Y} = \widehat{y^{AR}} + \widehat{resid}$

- 자기 상관이 설명하지 못한 부분을 강수, 침수 변수로 설명
- AR only 모델 TimeSeriesSplit 이용 생성 후, 잔차 생성
- 잔차를 강수, 침수 변수를 사용하여 Random Forest로 예측

Result :

AR-only TEST RMSE: 35.447
AR + residual(climate) TEST RMSE: 34.531
 Δ RMSE (improvement): 0.917



성능 개선 2.6 %

강수, 침수가 세균성 장관감염증 발생에 많은 영향을 준다고 보기 어려움.

03.2 수인성감염병 모델링 - 바이러스성



지연 상관 (Lag Correlation) 확인

* CCF 통해 결정

- 강수량 변수 : Lag 0, 침수 변수 : Lag 5, 기온 : Lag 4
수질변수 : lag1
- 감염병 발생 수(cases_bacteria) : Lag 3

전처리

- 바이러스는 겨울에 많이 발생, 강수량과 음의 상관관계
- > 자기상관, 온도, 계절성 통제 후 잔차 분석



03.2 수인성감염병 모델링 - 바이러스성

Prediction model

1) Random Forest

Test RMSE : 115.75

R^2 : 0.440

2) XGBoost

Test RMSE : 104.60


R^2 : 0.175

3) LightGBM

Test RMSE : 108.48



R^2 : 0.264

➡ Random Forest 모델의 성능이 가장 우수하다



03.2 수인성감염병 모델링 - 바이러스성

Prediction model




-
- 바이러스성 감염병 예측에는 수질지표, 온/습도, 계절 등이 주요 강수량 지표는 큰 영향력 없음
 - 건조 조건에서는 감염 증가 요인 X
 - 강수량 5~20mm 이하에서 강수변수는 감염 증가에 기여
 - 강수량 20mm 이상시 다시 shap값 0으로 수렴

03.3 수인성감염병 모델링 - 원충성

지연 상관 (Lag Correlation) 확인


* 상관계수 기준 결정

- 강수량 변수 : Lag 3, 4
침수 및 기온 변수 : Lag 5, 6, 7
- 수질 지표 : 성능 저하 및 지연효과 불규칙 -> 사용 X



전처리

- cases_protozoa skewed -> log 변환
- test/train set split :
2022년 test set, 2015~2021년 train set



03.3 수인성감염병 모델링 - 원충성



Baseline model

- 시계열 데이터 -> TimeSeriesSplit 활용 hyper parameter 튜닝

1) Light GBM

CV best RMSE : 1.242

Test RMSE : 0.477



03.3 수인성감염병 모델링 - 원충성



Baseline model

- 시계열 데이터 -> TimeSeriesSplit 활용 hyper parameter 튜닝

2) XGBoost

CV best RMSE : 0.546

Test RMSE : 0.465



03.3 수인성감염병 모델링 - 원충성



Baseline model

- 시계열 데이터 -> TimeSeriesSplit 활용 hyper parameter 튜닝

3) Random Forest

CV best RMSE : 0.539

Test RMSE : 0.470



03.3 수인성감염병 모델링 - 원충성

Baseline model

허들 모델(Hurdle model)

- 0이 많이 나오는 데이터(zero-heavy data) 분석할때 사용하는 모델 -> 원충성 모델에 적합 (log 변환 X)
- 1) 발생 여부 분류(Classification) : 이번주 감염병이 발생 할것인가(1), 아닌가(0) 예측 - LightGBM Classifier
 - Best ROC-AUC = 0.472
- 2) 발생강도 회귀(Regression) : 0 아닐 경우, 몇건 발생할 것인지 예측 - LightGBM Regressor
 - Best RMSE = 1.00, MAE = 0.6
 - * RMSE > MAE, 모델이 특정 이상치 예측에 실패, 질병 건수 예측시 평균적으로 0.6건 오차
 - $R^2 = 0.303$
- 3) Robust scaler 적용 시 R^2 0.67로 모델 성능 개선



04. 결과 및 추후과제

04.1 결과

Best Model

- 1) 세균성 장관감염증 : Random Forest model (Test RMSE 0.159)
+) 극한값(세균성 감염증 발생 수 상위10%) 발생 예측 : Light GBM model ($p = 0.786$)
- 2) 바이러스성 장관감염증 : Random Forest model($R^2 : 0.440$)
- 3) 원충성 장관감염증 : XGBoost(Test RMSE 0.465) or Hurdle model(robust-scaled, $R^2 : 0.67$)

한계점

- 1) 데이터 규모 및 해상도 한계 (지역별 수인성 감염병 발생 차이 미반영)
- 2) 비환경적 요인(개인 위생수준, 의료 접근성 등) 미반영
- 3) 계절성 요인의 강한 존재
- 4) Lag 구조 불확실성

04.2 기대 효과 및 추후 과제

기대 효과 및 활용 방안

- 1) 감염병 조기 경보 시스템 기반 마련
- 2) 기후 재난 대응 정책 지원
- 3) 환경보건 데이터 기반 의사결정 가능성 제시

추후과제

- 1) 지역단위 모델 확장
- 2) 기후변화 시나리오 기반 장기 예측
- 3) 추가 보건, 사회 변수 통합
- 4) 실제 조기경보 시스템 개발



Thank You